

Université de la Manouba

École Supérieure d'Économie Numérique



**Rapport
de projet de fin d'études**

Présenté en vue de l'obtention du diplôme de
Mastère Professionnel en Business Computing
Spécialité: **Data Science and Software Development**

Sujet

**Mise en place d'une plateforme intelligente d'analyse et de détection
des risques dans le processus Procure-to-Pay**

Élaboré par:

Ines boughanmi

Organisme d'accueil

FORVIA

Encadré par

ESEN
Société

M. Riadh Bouslimi
Mme Amel ben abid

Dédicaces

À la mémoire de mes grands-parents, Sadok et Chrifa,

Je dédie ce travail avec tout l'amour et la nostalgie qui habitent mon cœur. Votre sagesse, votre bonté ont tracé le chemin que je parcours aujourd'hui. Vous n'êtes plus là pour voir l'aboutissement de mes efforts, mais je sais que, de là où vous êtes, vous êtes fiers. Que Dieu vous accorde Sa miséricorde et vous garde dans Sa lumière éternelle.

À mes parents, Mustapha et Ilhem,

Je tiens à vous exprimer ma profonde gratitude pour votre soutien lors de la réalisation de mon projet de fin d'études. Vos encouragements constants et votre confiance en mes capacités ont été un pilier essentiel dans ma réussite. Ce mémoire est le fruit de votre dévouement et de votre sacrifice, et je suis fière de vous le dédier. Je vous aime infiniment.

À mon frère, Aymen,

Merci d'avoir été à mes côtés tout au long de ce parcours. Ta présence, ton soutien et tes conseils ont compté bien plus que tu ne le crois. Je te souhaite tout le succès que tu mérites.

À toute ma famille et à mes amis, qui ont, de près ou de loin, contribué à faire de moi ce que je suis aujourd'hui : merci du fond du cœur.

Remerciements

Je tiens à exprimer ma profonde gratitude envers toutes les personnes qui ont contribué à la réalisation de mon travail dans les meilleures conditions possibles.

Je tiens également à exprimer ma reconnaissance envers mon conseiller universitaire, **Dr. Riadh Bouslimi**, pour son engagement sans faille, ses conseils avisés et sa confiance en mon travail. Sa disponibilité et son expertise ont grandement contribué à l'aboutissement de mon projet.

En premier lieu, je souhaite remercier chaleureusement **Mme. Amel Ben Abid**, Regional Data Delivery Manager chez FORVIA, ainsi que **Achref**, Data Engineer, pour avoir généreusement accepté de m'accueillir en tant que stagiaire au sein de l'entreprise. Leur soutien, leurs conseils et leur accompagnement ont été précieux tout au long de mon stage.

Je n'oublie pas **les membres du jury** qui ont accepté d'évaluer mon travail et de me fournir des suggestions constructives pour son amélioration. Leur expertise et leur retour d'expérience ont été très précieux pour moi.

Enfin, je tiens à exprimer ma gratitude envers **l'ensemble du personnel enseignant et administratif de l'École Supérieure d'Économie Numérique** pour la qualité de la formation qu'ils m'ont dispensée et pour leur soutien tout au long de mes études. Leur engagement envers ma réussite a été une source d'inspiration pour moi.

Je souhaite que toutes ces personnes trouvent dans mon modeste travail une reconnaissance de l'impact positif qu'elles ont eu sur mon parcours académique et professionnel.

Abstract

This report presents the development of **IDP (Intelligent Data Platform)**, a supplier risk monitoring platform applied to the SAP Procure-to-Pay (P2P) process at FORVIA, the world's seventh largest automotive supplier, carried out within the FIT (Faurecia Informatique Tunisie) center in Tunis following the CRISP-DM methodology. The platform automates the detection and prioritization of financial and compliance anomalies across 294,722 SAP P2P transactions involving 2,293 suppliers, relying on a multi-dimensional feature engineering pipeline (30+ variables) and six complementary machine learning models (Logistic Regression, Random Forest, XGBoost, LightGBM, Isolation Forest, K-Means) combined with deterministic SAP business rules into a composite 0–100 risk score with four actionable levels (LOW, MEDIUM, HIGH, CRITICAL). It is served through a FastAPI REST backend and a React/TypeScript interactive dashboard, complemented by a Retrieval-Augmented Generation (RAG) chatbot (ChromaDB, sentence-transformers, Groq LLM API) enabling natural language queries over live risk data.

Keywords : Procure-to-Pay, SAP, Risk Scoring, Anomaly Detection, Machine Learning, Random Forest, XGBoost, Isolation Forest, RAG, FastAPI, React.

Résumé

Ce rapport présente le développement de **IDP (Intelligent Data Platform)**, une plateforme de surveillance des risques fournisseurs appliquée au processus SAP Procure-to-Pay (P2P) de FORVIA, septième équipementier automobile mondial, réalisée au sein du centre FIT (Faurecia Informatique Tunisie) à Tunis selon la méthodologie CRISP-DM. La plateforme automatise la détection et la priorisation des anomalies financières et de conformité sur 294 722 transactions SAP P2P impliquant 2 293 fournisseurs, à l'aide d'un pipeline d'ingénierie de variables multi-dimensionnel (plus de 30 variables) et de six modèles de Machine Learning complémentaires (Régression Logistique, Random Forest, XGBoost, LightGBM, Isolation Forest, K-Means) combinés à des règles métier SAP déterministes en un score de risque composite 0–100 réparti en quatre niveaux d'action (LOW, MEDIUM, HIGH, CRITICAL). Elle est exposée via un backend REST FastAPI et un tableau de bord interactif React/TypeScript, complétés par un chatbot RAG (*Retrieval-Augmented Generation*) basé sur ChromaDB, *sentence-transformers* et l'API Groq, permettant des requêtes en langage naturel sur les données de risque en temps réel.

Mots-clés : Procure-to-Pay, SAP, Score de risque, Détection d'anomalies, Machine Learning, Random Forest, XGBoost, Isolation Forest, RAG, FastAPI, React.

Table des matières

Notations et Abréviations	vii
Introduction générale	1
1 Cadre du projet	3
Introduction	3
1.1 Présentation de l'établissement d'accueil	3
1.1.1 Présentation de Forvia	3
1.1.2 Les activités de Forvia	4
1.1.3 Présentation de FIT	5
1.2 Présentation du projet	5
1.2.1 Contexte du projet	5
1.2.2 Étude de l'existant	6
1.2.3 Critique de l'existant	7
1.2.4 Solution proposée	7
1.3 Méthodologie de travail	9
1.3.1 Méthodologies de travail	9
1.3.2 Méthodologie retenue	11
1.4 Planification du projet	14
Conclusion	14
2 Compréhension et préparation des données	16
Introduction	16
2.1 Acquisition des données	16
2.1.1 Source des données	16
2.1.2 Format et structure des données	17
2.1.3 Volume et dimensions des données	18
2.2 Compréhension des données	18
2.2.1 Exploration des variables	19
2.2.2 Analyse des relations entre variables	20
2.2.3 Détection des problèmes potentiels	22
2.3 Prétraitement et ingénierie des features	24
2.3.1 Nettoyage des données	24

2.3.2	Ingénierie des features	25
2.3.3	Génération des labels proxy	28
2.3.4	Normalisation et mise à l'échelle	28
2.3.5	Gestion du déséquilibre de classes	28
2.4	Stockage et gestion des données	29
2.4.1	Organisation des fichiers de données	29
2.4.2	Datasets de production	30
2.4.3	Persistance des artefacts ML	30
	Conclusion	31
3	Modélisation et évaluation	32
	Introduction	32
3.1	Sélection et justification des modèles	32
3.1.1	Contexte théorique : Machine Learning pour la détection d'anomalies financières	32
3.1.2	Architecture multi-modèles	33
3.1.3	Modèles supervisés	33
3.1.4	Modèles non supervisés	36
3.2	Techniques d'entraînement et optimisation	38
3.2.1	Pipeline d'entraînement	38
3.2.2	Validation croisée	39
3.2.3	Paramètres des modèles	39
3.3	Évaluation des modèles	40
3.3.1	Métriques pour les modèles supervisés	40
3.3.2	Comparaison des performances des modèles supervisés	40
3.3.3	Métriques pour l'Isolation Forest	42
3.3.4	Métriques pour le K-Means	42
3.3.5	Importance des features	43
3.4	Moteur de scoring de risque composite	44
3.4.1	Architecture du moteur de scoring	44
3.4.2	Formule de scoring composite	44
3.4.3	Rôle effectif de chaque modèle dans le pipeline	46
3.4.4	Explicabilité des scores	47
3.5	Modélisation de l'assistant IA	47
3.5.1	Choix du modèle d'embedding	48
3.5.2	Choix de la base vectorielle	48
3.5.3	Choix du modèle de génération	49
3.5.4	Validation et limites de la modélisation RAG	49
	Conclusion	49

4	Déploiement et application web	51
	Introduction	51
4.1	Environnement de travail	51
4.1.1	Environnement matériel	51
4.1.2	Environnement logiciel	52
4.2	Conception de l'application	57
4.2.1	Diagramme de cas d'utilisation	58
4.2.2	Diagrammes de séquence	58
4.3	Présentation de la plateforme	60
4.3.1	Interfaces de la plateforme	61
4.3.2	Déploiement prévu de l'application sur Microsoft Azure	67
	Conclusion	70
	Conclusion générale	71

Liste des tableaux

1.1	Comparaison des méthodologies de travail	11
2.1	Caractéristiques du jeu de données (Documents1.csv)	18
2.2	Catégories de variables dans le jeu de données brut (Documents1.csv) .	19
2.3	Principales corrélations observées et leur interprétation	21
2.4	Labels proxy générés par le moteur de règles métier (colonne anomaly_type)	28
2.5	Organisation des répertoires de données du projet	30
3.1	Paramètres des modèles de Machine Learning	39
3.2	Performances comparatives des modèles supervisés sur le jeu de test (20 features)	41
3.3	Composantes du score de risque composite v2 et leurs pondérations recalibrées	45
3.4	Correspondance score de risque / niveau de risque	45
3.5	Rôle de chaque modèle dans le pipeline IDP	46
4.1	Caractéristiques de l'environnement matériel de développement	51
4.2	Logiciels et éditeurs utilisés	53
4.3	Bibliothèques Python utilisées, par domaine	54
4.4	Comparaison entre Ollama (local) et l'API Groq	65
4.5	Comparaison des solutions d'hébergement envisageables pour la plateforme IDP	70

Table des figures

1.1	Logo officiel de FORVIA [12]	4
1.2	Architecture générale de la plateforme IDP	8
1.3	Cycle de la méthodologie CRISP-DM [25]	9
1.4	Processus KDD (<i>Knowledge Discovery in Databases</i>) [14]	10
1.5	Étapes de la méthodologie SEMMA [10]	10
1.6	Cycle de la méthodologie TDSP (<i>Team Data Science Process</i>) [11] . . .	11
1.7	Cycle de la méthodologie CRISP-DM [25]	12
1.8	Diagramme de Gantt du projet IDP	14
2.1	Matrice de corrélation de Pearson entre les principales variables SAP P2P (log1p, 294 722 transactions)	20
2.2	Taux de valeurs manquantes par colonne dans les données brutes	22
2.3	Boxplots (échelle log1p) des features fournisseurs agrégées : présence de valeurs aberrantes dans toutes les variables	23
2.4	Répartition des classes de labels proxy (anomaly_type) : forte dominance de la classe NONE	23
2.5	Distribution du nombre de transactions par fournisseur dans le jeu de données agrégé	24
2.6	Impact de SMOTE sur l'équilibre des classes dans l'ensemble d'entraînement (avant : 235 777 échantillons, après : 677 148 échantillons) 29	
3.1	Architecture de la Régression Logistique : modèle linéaire avec fonction sigmoïde [23]	34
3.2	Architecture de la Random Forest : N arbres de décision entraînés par <i>bagging</i> , agrégés par vote majoritaire [7]	35
3.3	Principe de XGBoost : sous-échantillonnage des données et construction parallèle d'arbres correcteurs d'erreurs résiduelles [22]	35
3.4	Principe de LightGBM : construction séquentielle <i>leaf-wise</i> des arbres de boosting par gradient [16]	36
3.5	Architecture de l'Isolation Forest : les anomalies (nœuds foncés) sont isolées plus rapidement dans les iTrees que les observations normales [18]	37
3.6	Isolation Forest : distribution des scores d'isolation, répartition des anomalies détectées (5%) et scores par classe réelle sur le jeu de test . .	37

3.7	Principe du K-Means : avant clustering, les données sont non partitionnées; après, chaque point est affecté au cluster le plus proche [19]	38
3.8	Validation croisée à 5 plis du meilleur modèle (LightGBM) : F1-score macro sur les 5 plis	41
3.9	Importance des features — modèle LightGBM (sur les 20 features propres)	43
3.10	Principe général de l'architecture RAG appliquée à l'assistant IDP Chatbot [1]	48
4.1	Exemple de tableau de bord Power BI Desktop conçu pour la plateforme IDP	56
4.2	Flux Power Automate d'automatisation des alertes	57
4.3	Exemple d'alerte envoyée par courrier électronique aux équipes concernées	57
4.4	Diagramme de cas d'utilisation de la plateforme IDP	58
4.5	Diagramme de séquence – Authentification JWT et accès aux endpoints protégés	59
4.6	Diagramme de séquence – Requête à l'assistant IA conversationnel (RAG)	60
4.7	Architecture générale de la plateforme IDP	60
4.8	Dashboard principal de la plateforme IDP	61
4.9	Centre d'alertes de la plateforme IDP	62
4.10	Page Transactions de la plateforme IDP	63
4.11	Page Fournisseurs de la plateforme IDP	63
4.12	Assistant IA conversationnel IDP Chatbot	66
4.13	Restitution Power BI – suivi des contrats	67

Notations et Abréviations

API	Application Programming Interface
AUC	Area Under the Curve
CSV	Comma-Separated Values
CRISP-DM	Cross-Industry Standard Process for Data Mining
ERP	Enterprise Resource Planning
FIT	Faurecia Informatique Tunisie
GR	Goods Receipt (Réception marchandises)
HPA	Horizontal Pod Autoscaler
IDP	Intelligent Data Platform
IQR	Interquartile Range
IR	Invoice Receipt (Réception facture)
JWT	JSON Web Token
KPI	Key Performance Indicator
LGBM	Light Gradient Boosting Machine
LLM	Large Language Model
ML	Machine Learning
MLOps	Machine Learning Operations
P2P	Procure-to-Pay
PO	Purchase Order (Commande d'achat)
RAG	Retrieval-Augmented Generation
RF	Random Forest
ROC	Receiver Operating Characteristic
SAP	Systems, Applications and Products
SMOTE	Synthetic Minority Over-sampling Technique
SQL	Structured Query Language
XGB	XGBoost (eXtreme Gradient Boosting)

Introduction générale

La transformation numérique de l'industrie manufacturière s'accélère à un rythme sans précédent, portée par l'essor de l'intelligence artificielle, du Big Data et des plateformes analytiques avancées. Dans ce contexte, la maîtrise des risques opérationnels et financiers constitue un enjeu stratégique de premier ordre pour les grandes entreprises. Le processus Procure-to-Pay (P2P), qui couvre l'ensemble du cycle allant de la commande d'achat jusqu'au paiement du fournisseur, représente l'un des flux les plus critiques et les plus exposés aux anomalies dans les systèmes de gestion d'entreprise tels que SAP.

Chez FORVIA, septième équipementier automobile mondial, ce processus génère chaque année plusieurs centaines de milliers de transactions impliquant des milliers de fournisseurs répartis dans le monde entier. L'ampleur de ces volumes rend les contrôles manuels traditionnels insuffisants : les anomalies de rapprochement GR/IR (Goods Receipt / Invoice Receipt), le vieillissement non contrôlé des factures et l'absence de vision consolidée du risque fournisseur constituent autant de vulnérabilités susceptibles d'engendrer des pertes financières significatives et des écarts de conformité.

C'est dans ce contexte industriel exigeant que s'inscrit ce projet de fin d'études, réalisé au sein du centre FIT (Faurecia Informatique Tunisie) de FORVIA. Le projet consiste en le développement d'IDP — Intelligent Data Platform, une plateforme intelligente de surveillance et d'analyse des risques dans le processus SAP P2P. Cette plateforme repose sur une approche hybride combinant des règles métier déterministes et des modèles de Machine Learning afin de calculer un score de risque composite pour chaque transaction et chaque fournisseur.

L'intérêt de ce projet est à la fois scientifique, technique et opérationnel. Sur le plan scientifique, il met en œuvre une approche multi-modèles (classification supervisée, détection d'anomalies non supervisée et segmentation) pour répondre à une problématique réelle de surveillance de processus industriels. Sur le plan technique, il intègre un pipeline de Machine Learning complet — de l'ingestion des données brutes SAP jusqu'au déploiement d'une API REST et d'un tableau de bord interactif. Sur le plan opérationnel, il offre aux équipes achats et finance un outil de priorisation qui réduit significativement la charge de revue manuelle et accélère la détection des anomalies critiques.

Ce rapport est organisé en quatre chapitres qui suivent la progression logique du projet :

- **Chapitre 1 : Cadre du projet** — Présente l'entreprise d'accueil FORVIA et le centre FIT, expose la problématique du processus SAP P2P, décrit la solution proposée (IDP) et détaille la méthodologie CRISP-DM adoptée ainsi que la planification du projet.
- **Chapitre 2 : Compréhension et préparation des données** — Décrit les sources et la structure des données SAP P2P exploitées, présente l'analyse exploratoire, détaille le pipeline de nettoyage et de normalisation, et expose la démarche d'ingénierie des features qui a permis de construire plus de 30 variables pertinentes en 5 catégories.
- **Chapitre 3 : Modélisation et évaluation** — Présente et justifie le choix des six modèles de Machine Learning utilisés, décrit les techniques d'entraînement (validation croisée, SMOTE, normalisation), et analyse les performances obtenues à l'aide de métriques adaptées.
- **Chapitre 4 : Déploiement et application web** — Décrit l'architecture de déploiement de la plateforme IDP : API FastAPI, tableau de bord React, intégration de l'assistant IA RAG, et discute les perspectives d'industrialisation et de mise en production à grande échelle.

Nous concluons en synthétisant les apports du projet, en analysant ses limites et en proposant des axes d'amélioration pour les travaux futurs.

1

Cadre du projet

Introduction

Dans ce chapitre, nous allons présenter l'entreprise d'accueil FORVIA, en décrivant ses activités et son organisation mondiale. Nous présenterons ensuite le centre FIT (Faurecia Informatique Tunisie), au sein duquel ce stage a été effectué. Par la suite, nous exposerons le contexte du projet, la problématique identifiée ainsi que la solution développée. Enfin, nous décrirons la méthodologie de travail adoptée et le planning général du projet.

Ce chapitre s'articule comme suit : la Section 1.1 présente l'établissement d'accueil. La Section 1.2 décrit le projet et ses enjeux. La Section 1.3 détaille la méthodologie adoptée. La Section 1.4 expose la planification du projet. Enfin, la conclusion clôture ce chapitre.

1.1 Présentation de l'établissement d'accueil

Dans cette section, nous présentons le groupe FORVIA, ses pôles d'activités stratégiques, ainsi que le centre FIT, où ce stage a été réalisé.

1.1.1 Présentation de Forvia

FORVIA est l'un des leaders mondiaux de l'industrie automobile, né de la fusion entre Faurecia et Hella en 2022. Il se positionne comme le septième plus grand fournisseur automobile mondial, présent dans plus de 40 pays, avec plus de 300 sites de production et près de 150 000 employés à travers le monde. On estime qu'un véhicule sur deux dans le monde est équipé d'au moins un produit FORVIA.

Faurecia, fondée en 1997, s'est imposée comme un acteur incontournable dans quatre grands domaines : les sièges automobiles, les intérieurs de véhicules, les technologies de contrôle des émissions et les solutions de mobilité durable. Elle a développé une expertise reconnue dans l'allègement des structures et l'intégration de technologies embarquées.

Hella, fondée en 1899 en Allemagne, est l'un des pionniers mondiaux dans les systèmes d'éclairage automobile et l'électronique de véhicules. Son savoir-faire couvre

les technologies de vision, les capteurs, les systèmes de gestion de l'énergie et les solutions d'aide à la conduite (ADAS).

Ensemble, FORVIA réunit ces expertises complémentaires pour proposer des solutions innovantes répondant aux défis de la mobilité de demain : électrification, connectivité, autonomie et durabilité.

La Figure 1.1 représente le logo officiel du groupe FORVIA.



FIGURE 1.1 – Logo officiel de FORVIA [12]

Avec plus de 300 sites industriels, 63 centres de R&D et 150 000 collaborateurs dont plus de 35 000 ingénieurs répartis dans plus de 40 pays, FORVIA adopte une approche unique et globale pour relever les défis actuels et futurs de l'industrie automobile. Son objectif est de remplir sa mission de pionnier des technologies de mobilité, en proposant des expériences qui comptent pour les utilisateurs finaux.

1.1.2 Les activités de Forvia

FORVIA se compose de six pôles d'activités internationaux, chacun occupant une position de leader dans son secteur. Grâce à cette diversification stratégique, FORVIA propose des technologies innovantes couvrant tous les domaines clés de la mobilité de demain.

- **Sièges automobiles** : Les solutions de sièges de FORVIA sont conçues pour garantir une sécurité maximale et un confort optimal à bord. À l'échelle mondiale, ce pôle occupe la première place dans les systèmes de structure de sièges et la troisième place dans l'assemblage de sièges.
- **Intérieurs de véhicules** : FORVIA développe des solutions d'habitacle intégrant des technologies numériques avancées, des matériaux durables et des interfaces homme-machine (HMI) intuitives, répondant aux attentes croissantes des conducteurs en matière d'expérience à bord.
- **Mobilité propre** : Grâce à sa gamme de solutions couvrant le stockage et la distribution d'énergie, FORVIA accompagne la transition vers des véhicules à très faibles émissions (ULE) puis à zéro émission. FORVIA est le leader mondial des solutions ULE pour les véhicules particuliers et utilitaires.

- Électronique : Le pôle Électronique réunit les expertises de Faurecia et HELLA pour proposer une offre complète couvrant les capteurs, les actionneurs, la conduite automatisée, la gestion de l'énergie ainsi que le cockpit et les interfaces HMI.
- Éclairage automobile : Numéro 1 mondial des solutions électroniques et logicielles LED haut de gamme, la gamme FORVIA HELLA couvre tous les aspects de l'éclairage automobile : phares, feux arrière, éclairage de signalisation et éclairage intérieur.
- Solutions de cycle de vie : L'activité Lifecycle Solutions développe, produit et commercialise des produits d'éclairage et d'électronique destinés au marché indépendant des pièces de rechange, faisant de FORVIA HELLA l'un des principaux acteurs européens dans ce secteur.

1.1.3 Présentation de FIT

FIT (Faurecia Informatique Tunisie) est l'un des plus grands centres informatiques du groupe FORVIA, au sein duquel ce stage a été réalisé. Il s'agit d'une société à responsabilité limitée (SARL) fondée en 2009, employant environ 200 personnes, aussi bien en interne qu'en externe.

FIT est une entreprise technologique de premier plan dans l'industrie automobile, qui propose des solutions numériques et innovantes aux défis du secteur. Son équipe pluridisciplinaire est composée d'ingénieurs, de consultants, de développeurs, de chefs d'équipe et de managers, tous mobilisés autour de la transformation numérique du groupe FORVIA.

FIT intervient notamment dans les domaines suivants :

- Développement d'applications métier et de plateformes de données
- Intégration et maintenance des systèmes ERP (notamment SAP)
- Intelligence artificielle et analyse avancée des données industrielles
- Support et gouvernance des systèmes d'information du groupe

1.2 Présentation du projet

Dans cette section, nous définissons le contexte du projet, la problématique identifiée, ainsi que la solution développée durant le stage.

1.2.1 Contexte du projet

Dans le cadre de ce stage, nous travaillons sur le développement d'une plateforme intelligente de surveillance des risques fournisseurs dans le processus Procure-to-Pay

(P2P) de FORVIA, basée sur les données SAP.

Le processus Procure-to-Pay (P2P) désigne le cycle complet qui va de la commande d'achat jusqu'au paiement du fournisseur. Il englobe les étapes suivantes :

1. Commande d'achat (Purchase Order - PO) : émission d'une commande vers un fournisseur.
2. Réception des marchandises (Goods Receipt - GR) : enregistrement de la livraison physique des biens ou services.
3. Réception de la facture (Invoice Receipt - IR) : enregistrement de la facture émise par le fournisseur.

1.2.2 Étude de l'existant

les données du processus Procure-to-Pay (P2P) sont initialement gérées dans le système SAP de FORVIA (table *EKBE*, historique des mouvements associés aux documents d'achat). Toutefois, dans l'architecture data du groupe, les données SAP ne sont pas consommées directement par les projets analytiques : elles transitent d'abord par la plateforme Palantir, qui centralise, nettoie et transforme les données issues des différents systèmes sources de l'entreprise. Le flux de données suivi dans ce projet est donc le suivant :

SAP → Palantir → Extraction des données → Fichiers CSV → Projet IDP

Palantir est une plateforme d'intégration et d'analyse de données (*data integration & analytics platform*) qui permet de centraliser, croiser et transformer des volumes massifs de données provenant de systèmes hétérogènes (ERP, CRM, bases de données métiers). Au sein de FORVIA, Palantir joue le rôle de couche de centralisation et de transformation : il agrège les extractions issues de SAP et d'autres systèmes, applique des règles de nettoyage et de mise en cohérence, puis met à disposition des équipes des jeux de données structurés et directement exploitables. Cette architecture permet de découpler les projets analytiques des contraintes et de la complexité d'un accès direct aux systèmes SAP de production.

Dans le cadre de ce stage, les données nécessaires au projet IDP ont donc été extraites depuis Palantir sous forme de fichiers CSV structurés, contenant l'historique des mouvements de la table SAP *EKBE* (réceptions, factures, régularisations) déjà consolidé et mis en forme. Chaque ligne du fichier représente un événement dans le cycle de vie d'une ligne de commande : réception, facturation, régularisation, etc. Il est important de souligner que le projet ne se connecte donc pas directement aux systèmes SAP : il exploite des extraits déjà extraits, structurés et validés en amont par la chaîne Palantir, ce qui garantit la cohérence et la qualité des données d'entrée.

À ce jour, la surveillance de ces flux P2P repose sur des contrôles manuels effectués par les équipes comptables et achats, ainsi que sur des rapports SAP standards générés périodiquement. Cette approche présente des limites importantes dès lors que le volume de transactions devient important (plusieurs centaines de milliers de lignes par an).

1.2.3 Critique de l'existant

Le processus P2P de FORVIA génère un volume considérable de transactions impliquant plusieurs milliers de fournisseurs. L'absence d'un système automatisé de détection des anomalies entraîne plusieurs difficultés opérationnelles :

- Détection tardive des anomalies GR/IR : Les écarts entre les réceptions marchandises et les factures (GR/IR mismatches) ne sont pas détectés en temps réel. Ces écarts peuvent entraîner des sur-paiements ou des blocages de paiement, impactant la trésorerie de l'entreprise.
- Vieillesse non contrôlée des factures : Des factures anciennes restent non rapprochées pendant de longues périodes sans qu'aucune alerte ne soit générée, exposant l'entreprise à des risques financiers et comptables.
- Absence de scoring des risques fournisseurs : Il n'existe pas de vision consolidée du niveau de risque associé à chaque fournisseur, rendant difficile la priorisation des actions de contrôle et d'audit.
- Processus de revue manuel et chronophage : Les équipes doivent parcourir manuellement de nombreux rapports SAP pour identifier les transactions problématiques, ce qui représente une charge de travail importante et source d'erreurs humaines.
- Absence d'indicateurs de performance (KPI) centralisés : Il n'existe pas de tableau de bord unique permettant aux décideurs de visualiser en temps réel l'état des risques dans le processus P2P.

1.2.4 Solution proposée

Pour répondre à ces enjeux, nous développerons une plateforme complète de surveillance et d'analyse des risques fournisseurs dans le processus SAP P2P. La solution reposera sur trois composantes principales

- Pipeline Machine Learning : Un pipeline de traitement des données SAP, incluant le nettoyage, l'ingénierie des features, la détection d'anomalies par règles métier et des modèles de Machine Learning (Régression Logistique, Random Forest, XGBoost, LightGBM, Isolation Forest, K-Means). Ce pipeline calculera un score de risque composite (0-100) pour chaque transaction et chaque fournisseur.
- API REST (FastAPI) : Un backend exposant les résultats du pipeline via des endpoints REST sécurisés par authentification JWT. Il assurera le chargement

des données, l'orchestration du scoring et la mise à disposition des analyses pour le frontend.

- Dashboard Web interactif (React) : Une interface utilisateur moderne qui permettra aux analystes de visualiser les KPI globaux, d'explorer les profils fournisseurs, de filtrer et analyser les transactions à risque, et d'interagir avec un assistant IA basé sur la technologie RAG (*Retrieval-Augmented Generation*).
- Restitution Power BI et automatisation Power Automate : En complément du dashboard React, une restitution Power BI (KPI, transactions/contrats, alertes) sera développée pour les besoins de reporting métier, associée à des workflows d'alerte automatisés via Power Automate, en cohérence avec les outils déjà utilisés au sein de FORVIA.

Architecture générale

La Figure 1.2 synthétise l'enchaînement de ces quatre composantes sous la forme d'un pipeline global : les données SAP P2P brutes (commandes, réceptions, factures, paiements) alimentent le pipeline Machine Learning, qui calcule le score de risque composite à partir des règles métier et des modèles entraînés ; ce score est ensuite exposé par l'API REST FastAPI, consommée à la fois par le dashboard web React et par la restitution Power BI, cette dernière étant complétée par des workflows d'alerte automatisés via Power Automate.




FIGURE 1.2 – Architecture générale de la plateforme IDP

1.3 Méthodologie de travail

Avant d'arrêter notre choix méthodologique, nous avons étudié plusieurs approches reconnues pour la conduite de projets de science des données et de gestion de projet, afin de retenir celle la plus adaptée au contexte du projet IDP.

1.3.1 Méthodologies de travail

- CRISP-DM (*Cross-Industry Standard Process for Data Mining*) : CRISP-DM est un processus structuré en six phases itératives (compréhension métier, compréhension des données, préparation des données, modélisation, évaluation, déploiement), couvrant l'intégralité du cycle de vie d'un projet de science des données, depuis la définition des objectifs métier jusqu'au déploiement opérationnel de la solution, comme illustré à la Figure 1.3.





FIGURE 1.3 – Cycle de la méthodologie CRISP-DM [25]

- KDD (*Knowledge Discovery in Databases*) : Le KDD est l'une des premières méthodologies académiques de fouille de données. Il décompose le processus en cinq étapes : sélection des données, prétraitement, transformation, fouille de données (*data mining*) et interprétation/évaluation des résultats. Bien que pertinent pour structurer la dimension purement analytique, le KDD reste centré sur la phase de modélisation et n'intègre pas la compréhension du contexte métier ni le déploiement opérationnel de la solution (Figure 1.4).

FIGURE 1.4 – Processus KDD (*Knowledge Discovery in Databases*) [14]

- SEMMA (*Sample, Explore, Modify, Model, Assess*) : Développée par SAS Institute, SEMMA structure le travail analytique en cinq étapes : échantillonnage, exploration, modification, modélisation et évaluation. Cette méthodologie est étroitement liée à l'écosystème logiciel SAS et se concentre essentiellement sur les aspects techniques de la modélisation statistique, sans couvrir la compréhension métier en amont ni le déploiement en aval (Figure 1.5).





FIGURE 1.5 – Étapes de la méthodologie SEMMA [10]

- TDSP (*Team Data Science Process*) : Proposée par Microsoft, cette méthodologie structure les projets de science des données autour de cinq phases (compréhension métier, acquisition des données, modélisation, déploiement, acceptation client) et met l'accent sur la collaboration en équipe et l'outillage cloud (Azure). Elle s'avère cependant plus adaptée à des équipes data importantes opérant dans un écosystème Microsoft, ce qui dépasse le cadre d'un projet de stage individuel (Figure 1.6).

FIGURE 1.6 – Cycle de la méthodologie TDSP (*Team Data Science Process*) [11]

Le tableau 1.1 synthétise la comparaison entre les méthodologies de travail selon trois critères déterminants pour notre contexte : la couverture du cycle de vie data (de la compréhension métier au déploiement), l'adéquation avec un projet ML appliqué à des données SAP, et la faisabilité dans le cadre d'un stage individuel.

TABLE 1.1 – Comparaison des méthodologies de travail

Méthodologie	Couverture du cycle data	Orientation	Limite principale
KDD	Partielle (centrée modélisation)	Recherche académique en fouille de données	Ignore la compréhension métier et le déploiement
SEMMA	Partielle (centrée modélisation)	Modélisation statistique (écosystème SAS)	Dépendante d'un outillage propriétaire, pas de phase métier ni déploiement
TDSP	Complète	Équipes data à grande échelle (écosystème Azure)	Surdimensionnée pour un projet individuel
CRISP-DM	Complète et itérative	Projets data/ML génériques, indépendants de l'outillage	Retenue

1.3.2 Méthodologie retenue

Au regard de la nature analytique et orientée données de ce projet, nous avons retenu la méthodologie CRISP-DM (*Cross-Industry Standard Process for Data Mining*),

qui constitue la référence internationale pour les projets de science des données et de Machine Learning.

CRISP-DM est un processus structuré en six phases itératives, permettant de guider le projet depuis la compréhension du contexte métier jusqu’au déploiement opérationnel de la solution. La Figure 1.7 illustre les différentes phases de cette méthodologie.




FIGURE 1.7 – Cycle de la méthodologie CRISP-DM [25]

Les six phases de CRISP-DM appliquées à notre projet sont décrites ci-dessous :

- Compréhension métier (*Business Understanding*) : Analyse du processus SAP P2P de FORVIA, identification des risques opérationnels et financiers, définition des objectifs du scoring de risque et des KPIs attendus par les équipes achats et finance.
- Compréhension des données (*Data Understanding*) : Exploration des extraits SAP fournis (*Documents1.csv*), analyse de la structure des données P2P (PO, GR, IR, paiements), identification des variables pertinentes et des problèmes de qualité des données.
- Préparation des données (*Data Preparation*) : Nettoyage, normalisation et transformation des données SAP. Ingénierie des features multi-dimensionnelles (financières, temporelles, fournisseurs, opérationnelles) et génération de labels proxy basés sur les règles métier.

- Modélisation (*Modeling*) : Développement et entraînement des modèles de Machine Learning : classification supervisée (Régression Logistique, Random Forest, XGBoost, LightGBM), détection d'anomalies non supervisée (Isolation Forest) et segmentation fournisseurs (K-Means). Calcul du score de risque composite.
- Évaluation (*Evaluation*) : Validation des modèles par cross-validation, analyse des métriques (précision, rappel, F1-score, AUC-ROC) et vérification de la cohérence métier des scores de risque générés.
- Déploiement (*Deployment*) : Productisation des datasets de risque, développement de l'API FastAPI et du dashboard React, intégration de l'assistant IA (RAG), mise en service de la plateforme complète, ainsi qu'une réflexion sur l'industrialisation future via un déploiement prévu sur Microsoft Azure

Plusieurs raisons justifient ce choix :

- Couverture complète du cycle de vie du projet : Contrairement à Scrum (gestion de projet généraliste), au KDD et à SEMMA (centrés sur la seule modélisation), CRISP-DM encadre l'intégralité du projet, depuis la compréhension du processus métier SAP P2P jusqu'au déploiement de la plateforme IDP, en passant par la préparation des données et l'évaluation des modèles.
- Adéquation avec la nature du projet : Le projet IDP repose sur l'exploitation de données réelles issues de SAP, la construction de features métier, l'entraînement de plusieurs modèles (supervisés et non supervisés) et leur intégration dans une plateforme opérationnelle. CRISP-DM est précisément conçu pour ce type de démarche, où la compréhension du métier conditionne directement la qualité du modèle final.
- Caractère itératif et flexible : Les phases de CRISP-DM ne sont pas strictement linéaires : il est possible de revenir à une phase précédente (par exemple, retourner à la préparation des données après une évaluation insatisfaisante des modèles). Cette flexibilité s'est avérée essentielle dans notre projet, notamment lors de la recalibration des modèles en Phase 2 et de la productisation des données en Phase 3.
- Indépendance vis-à-vis de l'outillage : Contrairement à SEMMA (lié à SAS) ou à TDSP (lié à l'écosystème Microsoft Azure), CRISP-DM ne prescrit aucun outil particulier. Cette neutralité technologique a permis d'utiliser librement la pile technique retenue pour ce projet (Python, scikit-learn, FastAPI, React) sans contrainte méthodologique.
- Adaptabilité à un projet individuel : Étant un standard générique éprouvé dans l'industrie comme dans la recherche, CRISP-DM s'adapte aussi bien à de grandes équipes qu'à un projet mené par une seule personne dans le cadre d'un stage, contrairement à TDSP qui suppose une organisation en équipe data structurée.

Pour ces raisons, CRISP-DM constitue le cadre méthodologique le plus cohérent avec les objectifs, les contraintes et l’envergure du projet IDP.

1.4 Planification du projet

Cette section présente la planification globale du projet sous la forme d’un diagramme de Gantt, structuré en phases successives conformes au cycle CRISP-DM.

Le diagramme de Gantt présenté dans la Figure 1.8 fournit une chronologie visuelle des principales activités du projet, détaillant leur séquence et leur durée sur une période de vingt semaines, de février à juin.




FIGURE 1.8 – Diagramme de Gantt du projet IDP

Comme l’illustre la Figure 1.8, le projet débute en février par la compréhension du projet (S1-S4) menée en parallèle de l’exploration des données SAP, qui se poursuit jusqu’à la fin du mois de mars (S1-S8). À partir du mois d’avril, la préparation des données et le développement du tableau de bord Power BI sont conduits simultanément (S9-S12), avant d’enchaîner sur le choix, le développement et l’optimisation du modèle de scoring entre la mi-avril et la mi-mai (S11-S14). Enfin, de mai à juin, le développement de la plateforme web (dashboard React, S13-S18) est mené, marquant la clôture des vingt semaines de planification du projet.

Conclusion

Ce premier chapitre a posé le cadre général du projet : l’entreprise d’accueil FORVIA et le centre FIT, le contexte et la problématique du processus SAP P2P, ainsi que la

solution proposée – la plateforme IDP (Intelligent Data Platform) et son score de risque composite. Nous avons également justifié le choix de la méthodologie CRISP-DM face aux alternatives de travail, et présenté la planification du projet en quatre phases.

Le chapitre suivant décrit en détail la phase de compréhension et de préparation des données SAP P2P extraites via Palantir, qui constitue le socle de tout le pipeline analytique.

2

Compréhension et préparation des données

Introduction

La qualité des résultats d'un projet de Machine Learning repose avant tout sur la qualité et la compréhension des données exploitées. Ce chapitre décrit en détail les phases de compréhension et de préparation des données SAP P2P qui constituent le socle du pipeline analytique IDP. Conformément à la méthodologie CRISP-DM adoptée, ces phases couvrent l'acquisition des données, leur exploration approfondie, le nettoyage et la normalisation, et enfin l'ingénierie des features qui transforme les données brutes SAP en variables exploitables par les modèles de Machine Learning.

Ce chapitre est structuré comme suit : la Section 2.1 présente les sources et la structure des données. La Section 2.2 analyse en profondeur le contenu et les caractéristiques statistiques des données. La Section 2.3 détaille le pipeline de nettoyage, normalisation et ingénierie des features. La Section 2.4 décrit la gestion et le stockage des données. La conclusion clôture ce chapitre.

2.1 Acquisition des données

Cette section décrit les données exploitées dans le projet : leur origine dans le système SAP ERP de FORVIA, leur format et leur structure, ainsi que le volume et les dimensions du jeu de données brut utilisé tout au long du pipeline IDP.

2.1.1 Source des données

Les données exploitées dans ce projet trouvent leur origine dans le système SAP ERP de FORVIA, et plus précisément dans la table EKBE (*History per Purchasing Document*), qui enregistre l'historique complet de tous les mouvements associés aux documents d'achat (commandes, réceptions de marchandises, factures, régularisations).

Il est toutefois important de préciser que ces données ne sont pas interrogées directement depuis SAP. Comme indiqué au chapitre précédent, les données issues des systèmes sources de FORVIA (dont SAP) transitent d'abord par la plateforme Palantir, qui assure leur centralisation, leur nettoyage et leur transformation avant

leur mise à disposition sous forme de jeux de données structurés. Le flux suivi est donc : SAP → Palantir → extraction → fichiers CSV → projet IDP.

Ces extraits ont été obtenus depuis Palantir sous forme d'un fichier CSV dénommé `Documents1.csv`, déjà extrait, structuré et consolidé en amont par la chaîne Palantir. Ce fichier est placé dans le répertoire `src/data/raw/` du projet et constitue la source de vérité unique du pipeline. Le projet IDP travaille ainsi exclusivement sur des données déjà extraites et structurées, et non sur des requêtes en direct vers les systèmes SAP de production.

Il est important de noter que ces données sont des données internes d'entreprise : elles ne sont disponibles sur aucun dépôt public et leur usage est strictement encadré par les politiques de sécurité informatique de FORVIA. Ce choix de source de données est justifié par la nécessité de travailler sur des données réelles du contexte industriel cible, garantissant ainsi la pertinence et l'applicabilité des résultats.

Une fois la source et le flux d'acquisition établis, il convient de préciser le format concret de ces données ainsi que leur structure interne.

2.1.2 Format et structure des données

Le fichier `Documents1.csv` présente une structure tabulaire au format CSV (séparateur virgule), comportant 59 colonnes et 616 800 lignes brutes. Ces colonnes reflètent les champs SAP de la table EKBE enrichis d'informations issues des tables de référence SAP (EKKO pour les en-têtes de commandes, EKPO pour les postes, LFA1 pour les données fournisseurs). Chaque ligne représente un mouvement individuel dans le cycle de vie d'une ligne de commande d'achat. Après agrégation par la clé composite (numéro PO, numéro de poste), le jeu de données se réduit à **294 722 enregistrements** uniques représentant chacun l'état consolidé d'un poste de commande.

La nomenclature des colonnes suit une convention mixte alliant un nom fonctionnel et le code champ SAP, par exemple : `amount_||_ wrbtr_sum` (montant en devise locale), `posting_date_||_ budat_min` (date de comptabilisation), `supplier_||_ lifnr` (numéro fournisseur SAP).

Cette structure étant posée, il est utile de synthétiser les principales caractéristiques quantitatives du jeu de données afin d'en cerner précisément l'ampleur et les limites.

2.1.3 Volume et dimensions des données

Le Tableau 2.1 représente les caractéristiques du jeu de données brut :

TABLE 2.1 – Caractéristiques du jeu de données (Documents1.csv)

Caractéristique	Valeur
Lignes brutes (avant agrégation)	616 800
Nombre de colonnes brutes	59
Nombre de transactions (après agrégation PO/item)	294 722
Nombre de fournisseurs distincts (après traitement)	2 293
Période couverte	Données historiques FORVIA
Format	CSV (séparateur virgule)
Taille du fichier brut	≈ 240 Mo
Valeurs manquantes (avant traitement)	Présentes sur plusieurs colonnes
Déséquilibre de classes (labels proxy)	Classe majoritaire : NONE (95,73%)

Il convient de préciser que le fichier brut `Documents1.csv` référence en réalité 9 170 identifiants fournisseurs (`supplier_id`) distincts. Le chiffre de 2 293 fournisseurs retenu dans ce tableau correspond aux fournisseurs subsistant après le pipeline complet de nettoyage, d'agrégation par poste de commande et de filtrage des enregistrements non exploitables (données incomplètes, identifiants invalides ou mouvements résiduels sans rapprochement GR/IR) ; c'est ce périmètre consolidé qui alimente ensuite les datasets de production (Section 2.4).

Ce premier aperçu quantitatif révèle d'emblée deux contraintes majeures du projet : la présence de valeurs manquantes et un déséquilibre marqué entre classes. La section suivante approfondit l'exploration du contenu de ces données afin de caractériser précisément leur nature et leur qualité.

2.2 Compréhension des données

Cette section présente une analyse approfondie du jeu de données SAP P2P afin d'en comprendre la structure, la distribution et la qualité. Elle s'articule autour de deux axes : l'exploration des variables pour caractériser leur nature et leur comportement statistique, puis l'analyse des corrélations pour identifier les relations entre les features et orienter la phase d'ingénierie qui suit.

2.2.1 Exploration des variables

Les 59 colonnes du jeu de données brut couvrent quatre domaines d'information complémentaires, résumés dans le Tableau 2.2. Ces colonnes brutes constituent la matière première de l'ingénierie des features décrite en Section 2.3.

TABLE 2.2 – Catégories de variables dans le jeu de données brut (Documents1.csv)

Catégorie	Description
Identification	Clés SAP permettant de retracer chaque transaction : numéro PO, numéro de poste, identifiant fournisseur, code usine, organisation d'achat.
Variables financières	Montants des mouvements GR et IR, écarts GR/IR, montants bloqués, prix unitaires. Ces variables sont les indicateurs primaires du rapprochement Procure-to-Pay.
Variables temporelles	Dates de comptabilisation (première et dernière), date de facture, délais de traitement ; elles permettent de mesurer le vieillissement des transactions.
Variables catégorielles	Type de document d'achat, groupe de matières, conditions de paiement, indicateur d'accord-cadre ; elles décrivent le contexte contractuel et organisationnel.

Cette organisation en quatre catégories reflète la richesse des informations disponibles dans la table EKBE. Avant d'engager la phase de nettoyage et d'ingénierie, il est nécessaire d'analyser les relations entre ces variables afin d'identifier les redondances potentielles et de guider la sélection des features.

2.2.2 Analyse des relations entre variables

Une analyse des corrélations de Pearson a été réalisée sur l'ensemble des 294 722 transactions (montants transformés en log1p pour réduire l'effet des valeurs extrêmes). La Figure 2.1 présente la matrice complète couvrant 13 variables : les montants financiers (GR Amount, IR Amount, Blocked Amount), la quantité (Total Quantity), le prix unitaire (Unit Price), les indicateurs d'écart GR/IR (Delivery Gap, Invoice Ratio, GR/IR Gap %), le vieillissement (Aging Days), le score de risque (Risk Score), et les agrégats fournisseur (Supplier Spend, Tx Count, Anomaly Rate).




FIGURE 2.1 – Matrice de corrélation de Pearson entre les principales variables SAP P2P (log1p, 294 722 transactions)

Le Tableau 2.3 synthétise les relations les plus significatives observées dans la matrice et leur interprétation pour le pipeline d'ingénierie des features.

TABLE 2.3 – Principales corrélations observées et leur interprétation

Relation	r	Interprétation
Invoice Ratio $\leftrightarrow$ GR/IR Gap %	+1.00	Colinéarité parfaite : les deux variables mesurent le même concept (écart relatif GR/IR). L'une est écartée des modèles pour éviter la redondance.
GR Amount $\leftrightarrow$ IR Amount	+0.77	Forte corrélation positive (log1p) : sur les transactions normalement rapprochées, les montants GR et IR évoluent conjointement.
GR Amount $\leftrightarrow$ Blocked Amount	+0.75	Les transactions à montant GR élevé accumulent davantage de montants bloqués en attente de régularisation — signal de risque indirect.
Supplier Spend $\leftrightarrow$ Tx Count	+0.72	Relation structurelle : les fournisseurs à forte fréquence concentrent les dépenses totales les plus élevées.
Blocked Amount $\leftrightarrow$ Risk Score	+0.67	Le montant bloqué est le signal financier le plus fortement corrélé au score de risque : il traduit directement des litiges ou régularisations en cours.
Total Quantity $\leftrightarrow$ Unit Price	-0.68	Relation inverse forte : les commandes en grande quantité bénéficient de prix unitaires plus faibles (effet d'échelle). Les deux variables sont non-redondantes et conservées.
Invoice Ratio / GR/IR Gap % $\leftrightarrow$ Risk Score	-0.39 / -0.38	Résultat contre-intuitif : un ratio de facturation élevé est associé à un risque plus faible. Les transactions bien facturées ne génèrent pas d'anomalie ; c'est leur absence qui crée le risque.
Aging Days $\leftrightarrow$ Risk Score	+0.32	Vieillessement = signal de risque, conforme à l'hypothèse initiale : les transactions anciennes non clôturées accumulent du risque.
GR Amount $\leftrightarrow$ Delivery Gap	-0.04	Quasi-absence de corrélation linéaire : contrairement à l'hypothèse initiale, le montant GR ne prédit pas directement l'écart de livraison. La relation est non-linéaire et captée par les features d'écart dédiées.

Ces corrélations orientent directement les choix d'ingénierie des features et permettent d'anticiper les risques de redondance ou de fuite d'information. Elles s'accompagnent toutefois de plusieurs problèmes de qualité dans les données brutes, identifiés et caractérisés dans la sous-section suivante.

2.2.3 Détection des problèmes potentiels

L'exploration préliminaire a mis en évidence plusieurs problèmes de qualité des données :

- Valeurs manquantes : les données brutes présentaient des taux de valeurs manquantes élevés sur certaines colonnes peu renseignées (`outline_agreement_` | `batch_` | `charg` : ~90%), comme l'illustre la Figure 2.2. Ces colonnes ont été écartées de l'ingénierie des features. Les montants manquants (`gr_amount`, `ir_amount`) ont été imputés à 0 selon la logique métier : l'absence de mouvement financier équivaut à un montant nul. Après ce traitement, les features ML finales ne contiennent aucune valeur manquante. Au niveau agrégé (PO, item), 1.72% des couples ont un montant GR nul (`gr_amount` = 0) et 4.27% ont un montant IR nul (`ir_amount` = 0), signalant respectivement des anomalies potentielles de type DATA et ACCOUNTING.




FIGURE 2.2 – Taux de valeurs manquantes par colonne dans les données brutes

- Valeurs aberrantes : l'analyse par la méthode IQR (sur échelle logarithmique) révèle une proportion importante de valeurs aberrantes sur les variables fournisseurs agrégées : `supplier_total_spend`, `supplier_avg_amount`, `total_quantity`, `supplier_std_amount` et `supplier_transaction_count` présentent toutes des points extrêmes distants des moustaches (Figure 2.3). Ces valeurs correspondent à des fournisseurs de très grande envergure (dépenses cumulées de plusieurs millions d'euros) ou à des transactions unitaires exceptionnelles. Plutôt qu'une suppression, une winsorisation au 99^e percentile est appliquée (Section 2.3) afin de limiter leur influence sans perdre d'information.




FIGURE 2.3 – Boxplots (échelle log1p) des features fournisseurs agrégées : présence de valeurs aberrantes dans toutes les variables

- Déséquilibre de classes : après génération des labels proxy par le moteur de règles métier, les classes se répartissent de manière fortement déséquilibrée (Figure 2.4) : la classe `NONE` (transactions sans anomalie détectée) représente 95.73% des transactions (282 146), tandis que les classes `ACCOUNTING` (2.55%, soit 7 501 transactions) et `DATA` (1.72%, soit 5 075 transactions) sont fortement minoritaires. Ce déséquilibre justifie le recours à la technique SMOTE lors de la préparation des jeux d'entraînement (Section 2.3).




FIGURE 2.4 – Répartition des classes de labels proxy (`anomaly_type`) : forte dominance de la classe `NONE`

- Doublons et agrégation : les données brutes de la table `EKBE` contiennent plusieurs lignes par poste de commande (un enregistrement par mouvement de stock), avec en moyenne 2.09 lignes brutes par transaction agrégée (616 800 lignes pour 294 722 transactions finales). La Figure 2.5 illustre la distribution

du nombre de transactions par fournisseur dans le jeu de données agrégé : la majorité des fournisseurs concentrent entre 5 et 20 transactions, reflétant la diversité des volumes d'achat. Il est donc nécessaire d'agréger les données par la clé composite (PO, item) avant toute analyse.




FIGURE 2.5 – Distribution du nombre de transactions par fournisseur dans le jeu de données agrégé

- Hétérogénéité des formats : les dates sont stockées dans divers formats SAP nécessitant une normalisation systématique. Les codes fournisseurs numériques nécessitent un encodage avant utilisation dans les modèles ML.

Ces cinq problèmes de qualité, une fois identifiés et caractérisés, ont été systématiquement pris en charge dans le pipeline de prétraitement décrit dans la section suivante.

2.3 Prétraitement et ingénierie des features

Cette section présente le pipeline de transformation appliqué aux données brutes SAP afin de les rendre exploitables par les modèles de Machine Learning. Elle couvre successivement le nettoyage des données, l'ingénierie des features, la génération des labels proxy, la normalisation des variables et la gestion du déséquilibre de classes.

2.3.1 Nettoyage des données

Le pipeline de nettoyage, implémenté dans `src/scripts/sap_p2p_pipeline.py`, applique trois opérations successives :

- **Agrégation par poste de commande** : les enregistrements bruts de la table EKBE sont regroupés par la clé composite (numéro PO, numéro de poste). Les montants GR et IR sont sommés, les dates de comptabilisation agrégées en min/max, et les types de mouvement consolidés en flags booléens.
- **Gestion des valeurs manquantes** : les colonnes de montants sont imputées à 0 (logique métier : absence de mouvement = montant nul). Les colonnes catégorielles reçoivent la valeur UNKNOWN. Les colonnes très peu renseignées (`outline_agreement_|_konnr` : 100% manquants, `batch_|_charg` : ~90%) sont écartées.
- **Traitement des valeurs aberrantes** : une winsorisation au 99^e percentile est appliquée sur les variables financières (méthode IQR, échelle log1p), afin de limiter l'influence des transactions de très grande valeur sans perte d'information.

Une fois les données nettoyées et consolidées au niveau (PO, item), l'étape suivante transforme ces données brutes en un ensemble de variables prédictives structurées, exploitables par les modèles de Machine Learning.

2.3.2 Ingénierie des features

L'ingénierie des features constitue l'étape la plus critique du pipeline. Elle est centralisée dans la classe `FeatureEngineer` (`src/scripts/feature_engineering.py`), qui produit initialement plus de 30 features brutes organisées en 5 catégories distinctes. Après suppression des features constantes et des features trop fortement corrélées avec la variable cible (corrélation $> 0,7$, détectées par le script `ml_validation_clean.py`), le jeu de features retenu pour l'entraînement des modèles supervisés comprend **20 features propres**. Les features financières directement liées au cycle GR/IR (montants, écarts, ratios) sont exclues de l'entraînement ML mais conservées pour le calcul du score de risque composite (Section 3.4).

Features financières

Ces features capturent les caractéristiques monétaires de chaque transaction. Elles sont divisées en deux sous-groupes selon leur utilisation dans le pipeline :

Features financières utilisées dans le score de risque composite uniquement.

Ces features présentent une corrélation très élevée avec la variable cible (elles encodent partiellement ou totalement la règle métier du moteur de labels). Elles sont donc **exclues de l'entraînement des modèles supervisés** afin de ne conserver que des signaux réellement prédictifs, mais elles demeurent exploitées dans la composante `amount_anomaly` du score de risque :

- `gr_ir_difference` : différence brute entre montant GR et montant IR ($\Delta = GR - IR$).
- `abs_gr_ir_diff` : valeur absolue de l'écart GR/IR.
- `invoice_ratio` : rapport IR/GR, indicateur de sur- ou sous-facturation.
- `gr_ir_gap_pct` : écart en pourcentage : $\frac{|GR-IR|}{GR} \times 100$.
- `blocked_amount` : montant en attente de validation comptable.
- `amount_per_qty` : ratio montant/quantité, détecte les variations de prix anormales.

Features financières retenues pour l'entraînement ML. Ces features capturent les montants à un niveau d'agrégation moins directement corrélé au label :

- `unit_price` : prix unitaire calculé comme $\frac{\text{montant total}}{\text{quantité totale}}$.
- `total_quantity` : quantité totale cumulée sur le poste de commande.

Features temporelles

Ces features capturent la dynamique temporelle du cycle P2P :

- `days_in_system` : nombre de jours depuis la première comptabilisation (indicateur de vieillissement).
- `posting_month`, `posting_quarter`, `posting_day_of_week`, `posting_year` : décomposition temporelle pour capter la saisonnalité.
- `gr_ir_delay_flag` : indicateur binaire : la transaction dépasse-t-elle le seuil de délai normal (30 jours) ?
- `gr_ir_critical_delay` : délai critique (au-delà de 90 jours).
- `planned_delay_days` : écart entre la date réelle et la date de paiement prévue selon les conditions de paiement.

Features fournisseur

Ces features agrègent le comportement historique du fournisseur sur l'ensemble de ses transactions :

- `supplier_transaction_count` : nombre total de transactions avec le fournisseur.
- `supplier_total_spend` : dépenses totales agrégées sur le fournisseur.
- `supplier_avg_amount` : montant moyen par transaction fournisseur.
- `supplier_std_amount` : écart-type des montants (volatilité financière du fournisseur).
- `supplier_anomaly_rate` : proportion de transactions anormales détectées sur le fournisseur.

- `supplier_avg_aging` : vieillissement moyen des transactions du fournisseur.
- `supplier_high_risk` : indicateur : le fournisseur a-t-il un taux d'anomalies supérieur au seuil critique (20%) ?
- `supplier_high_volume` : indicateur : le fournisseur est-il parmi les fournisseurs à fort volume de transactions (quantile supérieur) ?

Features opérationnelles

Ces features capturent la complétude et la conformité du processus documentaire :

- `delivery_completed` : indicateur de clôture de livraison.
- `document_date_known` : indicateur de présence de la date du document.
- `has_outline_agreement` : présence d'un accord-cadre avec le fournisseur.
- `has_payment_terms` : présence de conditions de paiement négociées.

Encodage des variables catégorielles

Les variables catégorielles (code usine, groupe de matières, organisation d'achat, type de document) sont encodées par Label Encoding (attribution d'un indice numérique unique à chaque catégorie) afin d'être exploitables par les modèles arborescents et les modèles à base de distances.

Ces vingt features propres constituent le vecteur d'entrée X des modèles supervisés. Il reste à définir la variable cible y associée à chaque transaction, ce qui fait l'objet de la sous-section suivante.

2.3.3 Génération des labels proxy

En l'absence de données de fraude labellisées, le moteur de règles métier (`src/scripts/rule_engine.py`) génère des labels proxy basés sur l'état de rapprochement GR/IR de chaque transaction. Ces labels sont ensuite consolidés en trois classes dans la colonne `anomaly_type`, tels que définis dans le Tableau 2.4 :

TABLE 2.4 – Labels proxy générés par le moteur de règles métier (colonne `anomaly_type`)

Label	Condition de déclenchement	Effectif	Proportion
NONE	GR et IR présents et cohérents — transaction normale	282 146	95,73%
ACCOUNTING	Réception enregistrée sans facture correspondante (GR only)	7 501	2,55%
DATA	Documents partiels, données incomplètes ou non réconciliables	5 075	1,72%

Avec les labels proxy définis, le jeu de données est complet. Il convient à présent de normaliser les features numériques afin de garantir la convergence des modèles sensibles à l'échelle des variables.

2.3.4 Normalisation et mise à l'échelle

Avant l'entraînement des modèles sensibles à l'échelle des features (Régression Logistique, Isolation Forest), l'ensemble des features numériques est normalisé par `StandardScaler` (centrage à moyenne nulle, réduction à écart-type unitaire : $z = \frac{x-\mu}{\sigma}$). L'objet `scaler.pkl` est persisté pour être réutilisé de manière identique lors de l'inférence.

La normalisation ne résout cependant pas le problème du déséquilibre des classes identifié précédemment, qui doit être traité spécifiquement avant l'entraînement.

2.3.5 Gestion du déséquilibre de classes

Comme mis en évidence en Section 2.2.3, la variable cible `anomaly_type` présente un fort déséquilibre (ratio $\sim 23 : 1$ entre la classe `NONE` et les classes minoritaires). Entraîner un modèle directement sur ces données conduirait à un biais systématique en faveur de la classe majoritaire, au détriment des anomalies à détecter.

Pour y remédier, la technique SMOTE (*Synthetic Minority Over-sampling Technique*) est appliquée sur l'ensemble d'entraînement. SMOTE génère des exemples

synthétiques des classes minoritaires par interpolation dans l'espace des features entre des exemples existants et leurs k plus proches voisins ($k = 5$). La Figure 2.6 illustre l'effet de SMOTE : le jeu d'entraînement passe de 235 777 échantillons (déséquilibrés) à 677 148 échantillons équilibrés, avec 225 716 exemples par classe (NONE, ACCOUNTING, DATA).




FIGURE 2.6 – Impact de SMOTE sur l'équilibre des classes dans l'ensemble d'entraînement (avant : 235 777 échantillons, après : 677 148 échantillons)

L'ensemble des opérations décrites dans cette section — nettoyage, ingénierie des features, labellisation, normalisation et équilibrage SMOTE — produit un jeu de données prêt à l'entraînement. La section suivante décrit comment ces données et les artefacts associés sont organisés et stockés dans le projet.

2.4 Stockage et gestion des données

Cette section décrit l'organisation des données tout au long du pipeline IDP : la structure des répertoires de données, les datasets de production générés à l'issue du prétraitement et la persistance des artefacts ML pour garantir la reproductibilité des expériences.

2.4.1 Organisation des fichiers de données

Le pipeline de données est organisé selon une structure de répertoires claire reflétant les étapes de transformation, comme l'illustre le Tableau 2.5 :

TABLE 2.5 – Organisation des répertoires de données du projet

Répertoire	Contenu
<code>src/data/raw/</code>	Données brutes SAP : <code>Documents1.csv</code> (source de vérité, non modifiée)
<code>src/data/processed/</code>	Datasets nettoyés, features engineerées et labels proxy : <code>p2p_monitoring_dataset.csv</code> , <code>ml_features_phase2_X.csv</code> , <code>ml_features_phase2_y.csv</code>
<code>src/data/rule_based_labels/</code>	Labels générés par le Rule Engine : <code>documents_labels_*.csv</code>
<code>src/data/risk_scores/</code>	Scores de risque produits par le pipeline : <code>transactions_risk_table.csv</code> , <code>supplier_risk_table.csv</code>
<code>src/models/</code>	Artefacts des modèles entraînés : <code>*.pkl</code> , <code>scaler.pkl</code> , <code>model_registry.json</code>

Cette structure garantit la séparation stricte entre données brutes et données transformées, principe fondamental pour assurer la traçabilité et la reproductibilité du pipeline. À l'issue de ce pipeline, trois datasets de production sont générés pour alimenter les couches applicatives du projet.

2.4.2 Datasets de production

À l'issue du pipeline de préparation, trois datasets de production sont générés pour alimenter l'API et le tableau de bord :

- `transactions_risk_table.csv` : table des 294 722 transactions avec leurs features, scores de risque (`risk_score_transaction`, `risk_level_transaction`) et explications textuelles.
- `supplier_risk_table.csv` : profils de risque agrégés pour les 2 293 fournisseurs, incluant le score de risque fournisseur, le label de cluster K-Means, le taux d'anomalies et les indicateurs comportementaux.
- `monitoring_dataset.csv` : vue consolidée pour le tableau de bord de monitoring, avec les KPI temporels et les distributions de risque.

Ces datasets constituent l'interface entre le pipeline de données et les couches applicatives (API FastAPI, tableau de bord React). Leur cohérence est garantie par un mécanisme de persistance des artefacts ML décrit ci-après.

2.4.3 Persistance des artefacts ML

Les modèles entraînés et les objets de prétraitement sont persistés sous forme de fichiers pickle (`.pkl`) dans le répertoire `src/models/`. Un fichier registre

(`model_registry.json`) maintient les métadonnées de chaque artefact : date d'entraînement, version, métriques de performance, paramètres utilisés. Cette approche garantit la traçabilité et la reproductibilité des expériences.

Conclusion

Ce chapitre a présenté en détail le pipeline de compréhension et de préparation des données SAP P2P, qui constitue le fondement du projet IDP. Nous avons décrit la source des données (table EKBE de 59 colonnes et 616 800 lignes brutes, extraite via Palantir en CSV), analysé les caractéristiques statistiques du jeu de données après agrégation (294 722 transactions, 2 293 fournisseurs), identifié les problèmes de qualité (valeurs manquantes jusqu'à 100% sur certaines colonnes, déséquilibre de classes marqué à 95,73% / 2,55% / 1,72%, agrégation nécessaire) et présenté le pipeline complet de traitement : nettoyage, agrégation, ingénierie de plus de 30 features organisées en 5 catégories, génération de labels proxy (NONE, ACCOUNTING, DATA), normalisation StandardScaler et équilibrage SMOTE.

Ces préparations constituent le socle indispensable à la phase de modélisation. Le chapitre suivant présente les six modèles de Machine Learning mis en œuvre, leur justification, les techniques d'entraînement utilisées et les résultats d'évaluation obtenus.

3

Modélisation et évaluation

Introduction

Ce chapitre décrit le cœur analytique du projet IDP : la sélection, l'entraînement et l'évaluation des modèles de Machine Learning utilisés pour détecter les anomalies dans le processus SAP P2P et calculer le score de risque composite. Conformément à la méthodologie CRISP-DM, une architecture multi-modèles combinant apprentissage supervisé et non supervisé a été retenue afin de couvrir un large spectre d'anomalies.

Ce chapitre est organisé comme suit : la Section 3.1 présente et justifie les six modèles retenus. La Section 3.2 détaille les techniques d'entraînement et d'optimisation. La Section 3.3 présente les résultats d'évaluation et la comparaison des modèles. La Section 3.4 décrit le moteur de scoring de risque composite. La Section 3.5 présente la modélisation de l'assistant IA conversationnel basé sur l'architecture RAG. La conclusion clôture ce chapitre.

3.1 Sélection et justification des modèles

Cette section justifie le choix des six modèles de Machine Learning retenus pour la plateforme IDP. Elle situe d'abord ce choix dans le contexte théorique de la détection d'anomalies financières, avant de détailler l'architecture multi-modèles adoptée et de présenter individuellement chacun des modèles supervisés et non supervisés mis en œuvre.

3.1.1 Contexte théorique : Machine Learning pour la détection d'anomalies financières

La détection d'anomalies dans les données financières et comptables mobilise deux grandes familles d'approches, choisies en fonction de la disponibilité des labels [3] :

Approches supervisées — Lorsque des données labellisées sont disponibles, un classificateur est entraîné à distinguer transactions normales et anormales. En l'absence de données de fraude vérifiées dans notre contexte P2P, des **labels proxy** générés par le moteur de règles métier SAP (mismatches GR/IR, vieillissement, écarts de montants) servent de supervision indirecte. Des techniques comme **SMOTE** permettent de compenser le fort déséquilibre de classes inhérent à ce type de données [4]. Quatre

modèles supervisés complémentaires sont retenus : la Régression Logistique (référence interprétable), la Random Forest (robustesse et feature importance), et les algorithmes de boosting par gradient XGBoost [5] et LightGBM [16], reconnus pour leurs hautes performances sur données tabulaires.

Approches non supervisées — Lorsqu’aucun label n’est disponible, des méthodes non supervisées identifient les observations qui s’écartent statistiquement de la norme sans supervision préalable. L’**Isolation Forest** [18] détecte les anomalies transactionnelles en exploitant le principe que les observations anormales sont plus faciles à isoler dans un arbre aléatoire. Le **K-Means** segmente les fournisseurs en profils comportementaux homogènes, contextualisant ainsi le risque de chaque transaction par rapport au comportement habituel de son fournisseur.

L’architecture multi-modèles combinant ces deux familles offre une couverture plus large des types d’anomalies qu’une approche mono-modèle et constitue le cœur analytique de la plateforme IDP.

3.1.2 Architecture multi-modèles

La stratégie de modélisation adoptée repose sur une architecture multi-modèles complémentaires, où chaque modèle apporte un signal différent qui est ensuite combiné par le moteur de scoring :

- Modèles supervisés (Régression Logistique, Random Forest, XGBoost, LightGBM) : entraînés sur les labels proxy du moteur de règles, ils produisent une probabilité de risque basée sur les patterns appris dans les données historiques.
- Modèle d’anomalies non supervisé (Isolation Forest) : ne nécessite pas de labels et détecte les transactions qui s’écartent statistiquement de la norme, complétant les modèles supervisés dans les zones non couvertes par les règles métier.
- Modèle de segmentation (K-Means) : regroupe les fournisseurs en profils comportementaux homogènes, permettant de contextualiser le risque d’une transaction par rapport au comportement habituel du fournisseur.

3.1.3 Modèles supervisés

Régression Logistique

La Régression Logistique est le modèle de référence (*baseline*) du projet [8]. Elle modélise la probabilité d’appartenance à une classe via la fonction sigmoïde, qui transforme une combinaison linéaire des features en une probabilité comprise entre 0 et 1. Ses avantages dans notre contexte sont : l’interprétabilité directe de ses coefficients (les features à coefficients élevés sont les plus discriminantes), la rapidité d’entraînement, et la production naturelle de probabilités calibrées utilisables dans le moteur de scoring. Sa principale limitation est sa linéarité, qui ne lui permet pas

de capturer les interactions complexes entre features, d'où sa position de modèle de référence plutôt que de modèle de production. Son architecture est présentée à la Figure 3.1.




FIGURE 3.1 – Architecture de la Régression Logistique : modèle linéaire avec fonction sigmoïde [23]

Random Forest

La Random Forest (*Forêt Aléatoire*) est un ensemble de N arbres de décision entraînés sur des sous-échantillons aléatoires du jeu de données selon le principe du *bagging* [2]. La prédiction finale est obtenue par agrégation des probabilités de tous les arbres de la forêt. Ses avantages sont : la robustesse au surapprentissage grâce au *bagging*, la capacité à capturer des interactions non-linéaires entre features, et la fourniture de mesures d'importance des variables (*feature importance* par impureté de Gini), très utiles pour l'explicabilité des décisions. Dans notre projet, la Random Forest constitue le modèle supervisé de référence intermédiaire entre la Régression Logistique et les algorithmes de boosting. Son architecture est illustrée à la Figure 3.2.

Random Forest




FIGURE 3.2 – Architecture de la Random Forest : N arbres de décision entraînés par *bagging*, agrégés par vote majoritaire [7]

XGBoost

XGBoost (*eXtreme Gradient Boosting*) est un algorithme de boosting par gradient qui construit séquentiellement des arbres correcteurs d'erreurs résiduelles [5]. À chaque itération, un nouvel arbre est entraîné pour minimiser la perte résiduelle du modèle précédent, pondérée par un taux d'apprentissage. XGBoost intègre une régularisation L1/L2 sur les poids des feuilles, ce qui le rend robuste au surapprentissage sur des jeux de données de taille moyenne. Il gère également nativement les valeurs manquantes par apprentissage de la direction d'imputation optimale, un avantage appréciable sur des données SAP parfois incomplètes. Le principe de cet algorithme est schématisé à la Figure 3.3.




FIGURE 3.3 – Principe de XGBoost : sous-échantillonnage des données et construction parallèle d'arbres correcteurs d'erreurs résiduelles [22]

LightGBM

LightGBM (*Light Gradient Boosting Machine*) est une variante optimisée de XGBoost [16] reposant sur deux techniques innovantes : le *GOSS* (*Gradient-based One-Side Sampling*), qui conserve uniquement les instances aux gradients les plus élevés afin de réduire la taille effective du jeu d'entraînement sans perte significative de précision ; et l'*EFB* (*Exclusive Feature Bundling*), qui regroupe les features mutuellement exclusives pour réduire la dimensionnalité. Ces optimisations rendent LightGBM particulièrement adapté aux jeux de données de grande dimension (294 722 transactions, 30+ features) et lui permettent de produire des temps d'entraînement significativement plus courts que XGBoost pour des performances équivalentes, voire supérieures. La Figure 3.4 schématise ce principe de construction.




FIGURE 3.4 – Principe de LightGBM : construction séquentielle *leaf-wise* des arbres de boosting par gradient [16]

3.1.4 Modèles non supervisés

Isolation Forest

L'Isolation Forest est un algorithme de détection d'anomalies non supervisé fondé sur le concept d'*isolation* [18]. Son principe repose sur l'observation que les anomalies sont rares et structurellement différentes des observations normales : elles nécessitent donc en moyenne moins de partitions (*splits*) dans un arbre de décision aléatoire pour être isolées du reste des données. Plus une observation est isolée rapidement, plus son score d'anomalie est élevé. Un score proche de 1 indique une forte suspicion d'anomalie, un score proche de 0,5 une observation normale.

Dans notre pipeline, l'Isolation Forest est entraîné sur les features numériques normalisées avec un taux de contamination de 5% (`contamination=0.05`). Il produit un flag binaire (`anomaly_if_flag`) et un score continu (`anomaly_if_score`) pour chaque transaction. Ces sorties sont complétées par des détecteurs statistiques (Z-score, IQR) pour une validation croisée des anomalies détectées. Son architecture est représentée à la Figure 3.5.




FIGURE 3.5 – Architecture de l'Isolation Forest : les anomalies (nœuds foncés) sont isolées plus rapidement dans les iTrees que les observations normales [18]

La Figure 3.6 illustre la distribution des scores d'isolation et la répartition des anomalies détectées sur le jeu de test.




FIGURE 3.6 – Isolation Forest : distribution des scores d'isolation, répartition des anomalies détectées (5%) et scores par classe réelle sur le jeu de test

K-Means

L'algorithme K-Means [19] partitionne les fournisseurs en k groupes homogènes en cherchant à minimiser la dispersion intra-cluster, c'est-à-dire la somme des distances euclidiennes entre chaque fournisseur et le centroïde de son cluster. L'algorithme alterne entre deux étapes : l'affectation de chaque observation au cluster dont le centroïde est le plus proche, et la mise à jour des centroïdes par calcul de la moyenne des observations affectées. La méthode du coude combinée au Silhouette Score est utilisée pour déterminer le nombre optimal de clusters k . Les clusters obtenus sont ensuite profilés et labellisés en tiers de risque (*Tier-1 Strategic*, *Tier-2 Important*, *Tier-3 Tactical*) sur la base de leurs caractéristiques comportementales agrégées. Le principe

de l'algorithme est illustré à la Figure 3.7.




FIGURE 3.7 – Principe du K-Means : avant clustering, les données sont non partitionnées ; après, chaque point est affecté au cluster le plus proche [19]

3.2 Techniques d'entraînement et optimisation

Cette section décrit la mise en œuvre concrète de l'entraînement des modèles présentés précédemment : le pipeline suivi, la stratégie de validation croisée retenue pour en garantir la robustesse, et les paramètres effectivement utilisés pour chaque modèle.

3.2.1 Pipeline d'entraînement

L'entraînement est orchestré par le script `src/scripts/ml_validation_clean.py`, conçu pour garantir la qualité et la cohérence des données d'entraînement tout en reproduisant les étapes des notebooks `06_model_training.ipynb`. Le pipeline d'entraînement suit les étapes séquentielles suivantes :

1. Chargement des features : lecture de `ml_features_phase2_X.csv` (matrix X) et `ml_features_phase2_y.csv` (vecteur y).
2. Séparation train/test : division 80%/20% stratifiée par classe (`test_size=0.2`, `random_state=42`).
3. Normalisation : ajustement du `StandardScaler` sur le jeu d'entraînement uniquement (*fit on train, transform on both*).
4. Équilibrage SMOTE : application de SMOTE sur le jeu d'entraînement normalisé ($k = 5$ voisins).
5. Entraînement des modèles : entraînement des quatre modèles supervisés avec validation croisée ($k = 5$ folds).

6. Entraînement non supervisé : ajustement de l'Isolation Forest et du K-Means sur les features appropriées.
7. Persistance : sauvegarde des artefacts (*.pkl) et du registre (model_registry.json).

3.2.2 Validation croisée

La validation croisée k-fold stratifiée ($k = 5$) est utilisée pour les quatre modèles supervisés. Cette approche garantit :

- L'évaluation robuste des performances sur des sous-ensembles disjoints du jeu d'entraînement.
- La préservation de la distribution des classes dans chaque fold (stratification).
- La détection d'un éventuel surapprentissage via la comparaison des scores train vs. validation.

3.2.3 Paramètres des modèles

Le Tableau 3.1 présente les configurations des modèles utilisées dans le projet. Ces configurations sont définies dans `src/scripts/config.py`.

TABLE 3.1 – Paramètres des modèles de Machine Learning

Modèle	Paramètres principaux
Régression Logistique	<code>max_iter=1000</code> , <code>random_state=42</code> , <code>C=1.0</code> (régularisation L2)
Random Forest	<code>n_estimators=100</code> , <code>max_depth=15</code> , <code>random_state=42</code>
XGBoost	<code>n_estimators=100</code> , <code>learning_rate=0.1</code> , <code>max_depth=6</code> , <code>random_state=42</code>
LightGBM	<code>n_estimators=100</code> , <code>learning_rate=0.1</code> , <code>num_leaves=31</code> , <code>random_state=42</code>
Isolation Forest	<code>contamination=0.05</code> , <code>n_estimators=100</code> , <code>random_state=42</code> (valeur retenue après comparaison de 0.03, 0.05 et 0.10)
K-Means	<code>n_clusters=k*</code> (déterminé par méthode du coude), <code>random_state=42</code>

Ces valeurs résultent d'une recherche par grille (*grid search*) combinée à une validation croisée : pour chaque modèle, plusieurs combinaisons de paramètres ont été testées et celle maximisant le F1-score moyen sur les plis de validation a été retenue, tout en surveillant l'écart train/validation afin de limiter le surapprentissage. Le `random_state=42` est fixé pour tous les modèles afin de garantir la reproductibilité des résultats.

3.3 Évaluation des modèles

Cette section présente les métriques retenues pour évaluer chaque famille de modèles, puis les résultats obtenus : comparaison des quatre modèles supervisés, évaluation de l'Isolation Forest et du K-Means, et analyse de l'importance des features.

3.3.1 Métriques pour les modèles supervisés

Les modèles supervisés sont évalués à l'aide d'un ensemble complet de métriques adaptées au contexte déséquilibré de la détection d'anomalies.

Précision — Mesure la capacité du modèle à éviter les faux positifs (transactions normales classées comme anormales). Primordiale pour éviter les alertes injustifiées.

$$\text{Precision} = \frac{TP}{TP + FP} \quad (3.1)$$

Rappel — Mesure la capacité à détecter toutes les véritables anomalies. Primordial pour ne pas manquer de transactions risquées.

$$\text{Recall} = \frac{TP}{TP + FN} \quad (3.2)$$

F1-score — Moyenne harmonique entre précision et rappel ; métrique principale retenue pour les classes déséquilibrées.

$$F1 = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (3.3)$$

Accuracy — Proportion globale de prédictions correctes. Moins pertinente en cas de déséquilibre, présentée à titre de référence.

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (3.4)$$

ROC-AUC — Aire sous la courbe ROC ; mesure globale de la capacité discriminante du modèle, insensible au seuil de classification.

3.3.2 Comparaison des performances des modèles supervisés

Le Tableau 3.2 présente les performances réellement obtenues par les quatre modèles supervisés sur le jeu de test (20% des données), à l'issue de l'entraînement sur les données équilibrées par SMOTE.

TABLE 3.2 – Performances comparatives des modèles supervisés sur le jeu de test (20 features)

Modèle	CV F1 macro	CV Std	Train F1	Test F1
Régression Logistique	0,9255	$\pm 0,0007$	0,9256	0,8655
Random Forest	0,9587	$\pm 0,0014$	0,9593	0,9433
XGBoost	0,9916	$\pm 0,0010$	0,9920	0,9826
LightGBM	0,9949	$\pm 0,0017$	0,9954	0,9890

LightGBM atteint le meilleur F1-score macro de 0,9890 sur le jeu de test, bien au-delà du classifieur aléatoire ($AUC = 0,5$). Sur le jeu de test (58 945 transactions, répartis en trois classes : NONE pour les transactions normales, ACCOUNTING pour les écarts comptables GR/IR et DATA pour les données incomplètes), les erreurs de classification résiduelles du modèle se concentrent aux frontières entre classes voisines, ce qui est cohérent avec la nature continue des anomalies P2P.

La validation croisée à 5 plis (Figure 3.8) confirme la stabilité des résultats de LightGBM : CV F1 macro = 0,9949 ($\pm 0,0017$) sur les cinq plis, avec une variance inter-plis très faible, indiquant une bonne généralisation sans surapprentissage.




FIGURE 3.8 – Validation croisée à 5 plis du meilleur modèle (LightGBM) : F1-score macro sur les 5 plis

Analyse et interprétation : LightGBM obtient les meilleures performances (Test F1 = 0,9890), suivi de XGBoost (0,9826), Random Forest (0,9433) et Régression Logistique (0,8655). Les features financières directement corrélées à la variable cible

(corrélation de Pearson $> 0,70$ avec `anomaly_type`) — notamment `gr_ir_difference`, `invoice_ratio`, `has_gr`, `has_ir`, `gr_amount`, `total_ir_amount` — ont été **retirées du jeu d'entraînement** afin de ne conserver que des signaux réellement prédictifs. Les 20 features retenues pour l'entraînement ML sont issues des catégories temporelles, comportement fournisseur et opérationnelles (voir Section 2.3). Les performances obtenues reflètent ainsi la capacité réelle des modèles à détecter des anomalies à partir de signaux indirects, sans réapprendre les règles du moteur de labellisation. Il convient cependant de noter que la classe `INVOICED_NOT_DELIVERED` (fraude potentielle) est absente du jeu de données disponible (0 occurrence sur 294 722 transactions), ce qui constitue la principale limite de la validation présentée : les modèles sont évalués sur un problème à trois classes (`NONE`, `ACCOUNTING`, `DATA`) et leur capacité à détecter des cas de fraude réelle reste à valider sur des données complémentaires.

3.3.3 Métriques pour l'Isolation Forest

L'évaluation de l'Isolation Forest s'effectue de manière différente en l'absence de labels vérifiés :

- Taux d'anomalies détectées (avec `contamination=0.05`, valeur retenue en production) : environ 5% des transactions sont flaggées comme anormales, cohérent avec les attentes métier.
- Validation manuelle : les transactions avec le score d'anomalie le plus élevé sont inspectées manuellement pour vérifier leur pertinence métier (GR/IR mismatches, montants extrêmes, vieillissement important).
- Comparaison avec les labels proxy : le taux de concordance entre les flags de l'Isolation Forest et les classes anormales du Rule Engine (`INVOICED_NOT_DELIVERED`, `DELIVERED_NOT_INVOICED`) est calculé comme indicateur de cohérence.
- Tests statistiques complémentaires : les détecteurs Z-score et IQR sont utilisés pour valider les anomalies identifiées par l'Isolation Forest.

3.3.4 Métriques pour le K-Means

La qualité de la segmentation K-Means est évaluée par :

- Silhouette Score : mesure la cohésion intra-cluster et la séparation inter-cluster. Un score proche de 1 indique des clusters bien définis. La méthode du coude sur le Silhouette Score guide le choix du nombre optimal de clusters k .
- Profilage des clusters : les centroïdes de chaque cluster sont analysés pour attribuer une signification métier (ex. : *Cluster 0 = Fournisseurs haute fréquence / faible risque*, *Cluster 1 = Fournisseurs occasionnels / risque moyen*).

3.3.5 Importance des features

L'analyse de l'importance des variables (*feature importance*) fournie par le modèle LightGBM permet d'identifier les features les plus discriminantes parmi les **20 features propres** retenues pour l'entraînement. La Figure 3.9 présente le classement des features selon leur importance dans le modèle final.

Il est important de noter que les features financières directement liées au cycle GR/IR (`total_ir_amount`, `invoice_ratio`, `gr_ir_gap_pct`, `gr_ir_difference`, `blocked_amount`, etc.) ont été **exclues de l'entraînement** car elles encodent directement la règle de génération des labels (corrélation $> 0,70$ avec `anomaly_type`). Les features qui contribuent au modèle LightGBM sont donc :

- **Features temporelles** : `days_in_system` (vieillessement de la transaction), `posting_month`, `posting_quarter`, `posting_day_of_week`, `gr_ir_delay_flag`, `gr_ir_critical_delay`, `planned_delay_days`.
- **Features fournisseur** : `supplier_transaction_count`, `supplier_total_spend`, `supplier_avg_amount`, `supplier_std_amount`, `supplier_avg_aging`.
- **Features opérationnelles** : `delivery_completed`, `document_date_known`, `has_outline_agreement`, `has_payment_terms`.
- **Features de prix** : `unit_price`, `total_quantity`.




FIGURE 3.9 – Importance des features — modèle LightGBM (sur les 20 features propres)

Cette hiérarchie illustre que, en l'absence de features financières GR/IR directes, les modèles s'appuient sur des signaux *indirects* pour détecter les anomalies : le vieillissement de la transaction (`days_in_system`), la volatilité financière du

fournisseur (`supplier_std_amount`), et les indicateurs de complétude documentaire. Ces features constituent une base d'inférence plus robuste pour la généralisation en production, car elles ne dépendent pas des champs GR/IR qui peuvent être absents ou incomplets dans certains flux SAP.

3.4 Moteur de scoring de risque composite

Cette section décrit comment les sorties des différents modèles présentés précédemment sont combinées au sein d'un moteur de scoring unique : son architecture, la formule de scoring composite, le rôle effectif de chaque modèle dans le pipeline, et l'explicabilité des scores produits.

3.4.1 Architecture du moteur de scoring

Le moteur de scoring de risque composite, implémenté dans `src/scripts/risk_scoring_engine.v2.py` (version recalibrée Phase 2), transforme les sorties brutes des modèles ML et des règles métier en un score de risque unique, normalisé et explicable. Son architecture distingue deux niveaux de scoring :

- Scoring transactionnel (`Phase2TransactionRiskScorer`) : calcule `risk_score_transaction` pour chaque transaction individuelle.
- Scoring fournisseur (`SupplierRiskScorer`) : agrège les scores transactionnels et les features comportementales pour calculer `supplier_risk_score`.

3.4.2 Formule de scoring composite

Le score de risque transactionnel (version 2, recalibrée) est calculé comme une combinaison pondérée de **sept composantes** :

$$\text{risk_score} = \sum_i w_i \cdot s_i \quad (3.5)$$

$$\begin{aligned} &= 0,20 \cdot s_{\text{règles}} + 0,25 \cdot s_{\text{anomalie}} + 0,15 \cdot s_{\text{ML}} \\ &\quad + 0,15 \cdot s_{\text{montant}} + 0,10 \cdot s_{\text{temporal}} + 0,10 \cdot s_{\text{fréq.}} + 0,05 \cdot s_{\text{volatilité}} \end{aligned} \quad (3.6)$$

Les sept composantes sont définies dans le Tableau 3.3 :

TABLE 3.3 – Composantes du score de risque composite v2 et leurs pondérations recalibrées

Composante	Poids	Calcul
Signal règles métier ($s_{\text{règles}}$)	20%	NONE→0, DATA→30, ACCOUNTING→60, INVOICED_NOT_DELIVERED→80. Réduit (v1 : 40%) car la majorité des transactions est NONE.
Classification anomalie (s_{anomalie})	25%	NONE→20, DATA→35, ACCOUNTING→60, FRAUD→100. Composante directe sur le type d'anomalie détecté.
Probabilité ML (s_{ML})	15%	$(1 - \text{confidence_LightGBM}) \times 100$: plus la confiance est faible, plus le score ML est élevé.
Anomalie de montant (s_{montant})	15%	Composite de <code>gr_ir_gap_pct</code> , <code>invoice_ratio</code> et <code>blocked_amount_pct</code> (features du scoring, non utilisées en ML).
Signal temporel (s_{temporal})	10%	Paliers recalibrés selon <code>days_in_system</code> : $\leq 30j \rightarrow 5$, $30-90j \rightarrow 15$, $90-180j \rightarrow 35$, $180-365j \rightarrow 65$, $> 365j \rightarrow 95$.
Fréquence fournisseur ($s_{\text{freq.}}$)	10%	Score basé sur la fréquence de transactions du fournisseur : faible fréquence → risque plus élevé (comportement imprévisible).
Volatilité fournisseur ($s_{\text{volatilité}}$)	5%	Score basé sur l'écart-type des montants du fournisseur : forte volatilité → risque plus élevé.

Le score final est normalisé et clampé dans l'intervalle $[0, 100]$, puis converti en niveau de risque discret selon la correspondance du Tableau 3.4 :

TABLE 3.4 – Correspondance score de risque / niveau de risque

Score	Niveau	Signification opérationnelle
$[0, 25)$	LOW	Transaction normale, aucune action requise
$[25, 50)$	MEDIUM	Mérite une revue, faible urgence
$[50, 75)$	HIGH	Revue recommandée, action à programmer
$[75, 100]$	CRITICAL	Action immédiate recommandée, blocage possible

3.4.3 Rôle effectif de chaque modèle dans le pipeline

Si les six modèles présentés dans ce chapitre sont tous entraînés et évalués au cours de la phase de modélisation, ils n'interviennent pas tous de la même manière dans le score de risque composite (équation 3.6). Le Tableau 3.5 précise le rôle effectif de chacun.

TABLE 3.5 – Rôle de chaque modèle dans le pipeline IDP

Modèle	Rôle dans le pipeline
Régression Logistique	Modèle de référence interprétable, comparé aux autres modèles supervisés (Tableau 3.2); ne contribue pas directement au score composite.
Random Forest	Entraîné et comparé; ses résultats (Test F1 = 0,9433) servent de référence intermédiaire entre la Régression Logistique et les modèles de boosting; ne contribue pas directement au score composite en production.
XGBoost	Entraîné et comparé (CV F1 = 0,9916, Test F1 = 0,9826); ses sorties ne sont pas réinjectées dans la formule de scoring en production.
LightGBM	Meilleur modèle (CV F1 = 0,9949, Test F1 = 0,9890); sélectionné en production dans <code>ml_validation_clean.py</code> pour produire la confiance de prédiction s_{ML} utilisée dans la composante <i>Probabilité ML</i> (15 %) du score composite. Exposé via l'endpoint <code>GET /ml/predict/{transaction_id}</code> .
Isolation Forest	Détection d'anomalies non supervisée (contamination = 0,05, 2 948 anomalies détectées sur 58 945 transactions de test); son score d'isolation (<code>ml_isolation_score</code>) est exposé via l'API (<code>GET /ml/anomalies</code>) pour le tri des transactions suspectes.
K-Means	Segmentation des fournisseurs en $k = 2$ clusters (Silhouette = 0,9923); le label de cluster (<code>ml_cluster</code>) est exposé via l'API et exploité pour le profilage Supplier 360; n'intervient pas dans le calcul direct de <code>risk_score_supplier</code> .

En définitive, LightGBM est le modèle de production qui alimente directement le score composite via la composante *Probabilité ML* (15 %), sélectionné après comparaison objective des quatre modèles sur 20 features propres. Les autres modèles supervisés (Régression Logistique, Random Forest, XGBoost) participent à la démarche de comparaison et de justification de l'approche multi-modèles (Section 3.3). L'Isolation Forest et le K-Means fournissent respectivement le score d'anomalie non supervisé et la segmentation fournisseur, tous deux exposés via les nouveaux endpoints

API `/ml/predict` et `/ml/anomalies`. Cette distinction entre *modèles évalués* et *modèle effectivement pondéré dans le score* reflète une approche pragmatique : l'ensemble multi-modèles valide la robustesse de la détection, tandis qu'un unique modèle de production (LightGBM) assure la stabilité et la traçabilité du score diffusé aux équipes métier.

3.4.4 Explicabilité des scores

Pour chaque transaction scorée, le moteur génère un texte d'explication lisible par les équipes métier (**RiskExplainer**), identifiant les facteurs de risque dominants : type d'anomalie détectée, magnitude de l'écart GR/IR, durée de vieillissement, et contexte fournisseur. Cette explicabilité est fondamentale pour l'adoption de la solution par les équipes non techniques.

3.5 Modélisation de l'assistant IA

En complément des modèles de scoring de risque, le projet IDP intègre un second volet de modélisation orienté traitement du langage naturel : l'assistant conversationnel *IDP Chatbot*, fondé sur l'architecture RAG (*Retrieval-Augmented Generation*). Cette section décrit les choix de modélisation effectués pour cette composante — modèle d'embedding, base vectorielle et modèle de génération — ainsi que leur justification et leurs limites ; le flux applicatif détaillé (requête, encodage, récupération, génération) est quant à lui présenté au Chapitre 4.

Le paradigme RAG combine la puissance des grands modèles de langage (LLM) avec un mécanisme de récupération d'information contextualisée [17]. Son architecture typique comprend trois composants : l'indexation, où les documents ou enregistrements de données sont encodés sous forme de vecteurs denses (*embeddings*) à l'aide d'un modèle de représentation sémantique ; la récupération, où les k documents les plus similaires sémantiquement à la requête utilisateur sont récupérés depuis une base de données vectorielle ; et la génération, où le contexte récupéré est injecté dans le prompt d'un LLM qui produit une réponse en langage naturel fondée sur les données réelles. Cette architecture garantit que les réponses du chatbot sont ancrées dans les données réelles du projet (scores de risque, profils fournisseurs, anomalies détectées), évitant ainsi les hallucinations caractéristiques des LLM utilisés en mode génératif pur.

La Figure 3.10 rappelle le principe général de cette architecture, appliqué dans notre cas à l'interrogation des données fournisseurs, transactions et contrats du projet IDP.




FIGURE 3.10 – Principe général de l'architecture RAG appliquée à l'assistant IDP Chatbot [1]

3.5.1 Choix du modèle d'embedding

La génération des représentations vectorielles repose sur `all-MiniLM-L6-v2` (*sentence-transformers*), un modèle de 22 millions de paramètres. Ce choix résulte d'un compromis entre qualité sémantique et performance : contrairement à des modèles plus volumineux (BERT-large, modèles multilingues lourds), `all-MiniLM-L6-v2` permet un encodage quasi instantané des requêtes utilisateur, condition nécessaire à une expérience conversationnelle fluide dans le dashboard, tout en offrant une qualité de représentation sémantique suffisante pour discriminer les profils fournisseurs, transactions et contrats indexés dans le corpus du projet.

3.5.2 Choix de la base vectorielle

ChromaDB a été retenue comme magasin vectoriel pour la collection persistante `p2p_copilot_v2`. Cette base légère, exécutable en mémoire ou persistée sur disque sans infrastructure serveur dédiée, s'avère adaptée à l'échelle du corpus du projet (2 293 fournisseurs, transactions à risque, contrats), tout en s'intégrant nativement à la pile Python du backend FastAPI sans dépendance externe lourde.

3.5.3 Choix du modèle de génération

Le modèle de génération a évolué au cours du projet : de `llama3.2:1b` exécuté localement via Ollama, vers `llama-3.3-70b-versatile` exposé par l'API cloud Groq, retenu en version finale pour la qualité et la fiabilité de ses réponses. La justification détaillée de cette évolution, ainsi que le tableau comparatif correspondant, sont présentés au Chapitre 4 (Tableau 4.4).

3.5.4 Validation et limites de la modélisation RAG

À la différence des modèles supervisés et non supervisés présentés dans ce chapitre, l'assistant RAG ne se prête pas à une évaluation quantitative par métriques de classification (Precision, Recall, F1, ROC-AUC) : sa sortie est un texte généré, non une prédiction discrète. Sa validation repose donc sur une approche qualitative : vérification manuelle de la pertinence des réponses sur un ensemble de questions métier types (profil fournisseur, transactions à risque, explication de score), et contrôle de l'ancrage des réponses dans les données réelles récupérées par ChromaDB afin de limiter les hallucinations propres aux LLM génératifs. Le mécanisme de *fallback* déterministe (Chapitre 4) constitue par ailleurs une garde-fou supplémentaire : en l'absence de réponse fiable du LLM, une réponse structurée est reconstruite directement depuis les métadonnées récupérées, plutôt que depuis une génération libre. Cette absence de métrique quantitative formelle constitue une limite assumée de la modélisation RAG, identifiée comme axe d'amélioration future (évaluation automatisée par LLM-as-judge, par exemple).

Conclusion

Ce chapitre a présenté en détail l'architecture de modélisation du projet IDP, combinant six modèles complémentaires : quatre modèles supervisés (Régression Logistique, Random Forest, XGBoost, LightGBM) entraînés sur **20 features propres**, un détecteur d'anomalies non supervisé (Isolation Forest, contamination = 0,05) et un algorithme de segmentation (K-Means, $k = 2$). Nous avons décrit les techniques d'entraînement utilisées (validation croisée k-fold, SMOTE, StandardScaler) et présenté les métriques d'évaluation adaptées à chaque type de modèle. **LightGBM** s'impose comme meilleur modèle avec un F1-score macro de 0,9890 sur le jeu de test, après suppression explicite des features trop fortement corrélées avec la variable cible. Enfin, nous avons détaillé le moteur de scoring de risque composite v2 qui agrège sept composantes en un score explicable sur une échelle 0–100, ainsi que la modélisation de l'assistant IA conversationnel RAG (choix du modèle d'embedding `all-MiniLM-L6-v2`, de la base vectorielle ChromaDB et du modèle de génération `llama-3.3-70b-versatile`), validé qualitativement en l'absence de métrique de

classification applicable.

Cette architecture multi-modèles constitue la valeur ajoutée principale du projet IDP par rapport aux approches règles-seules ou modèle-unique. Le chapitre suivant décrit le déploiement de ces résultats à travers la plateforme web IDP : l'API FastAPI, le tableau de bord React et l'assistant IA RAG.

4

Déploiement et application web

Introduction

La phase de déploiement constitue l’aboutissement du cycle CRISP-DM : elle transforme les résultats du pipeline ML en une plateforme opérationnelle utilisable par les équipes métier. Ce chapitre présente, dans un premier temps, l’environnement de travail mobilisé pour développer la plateforme IDP (Intelligent Data Platform) — matériel, langages, logiciels, bibliothèques Python et outils de communication. Il décrit ensuite, interface par interface, la plateforme telle qu’elle a été développée : authentification, dashboard, centre d’alertes, exploration des transactions et des fournisseurs, assistant IA conversationnel, module analytique et restitution Power BI. Enfin, il présente le déploiement prévu de la plateforme sur Microsoft Azure, qui constituerait l’environnement de production envisagé pour l’industrialisation du projet, et discute les axes ayant motivé ce choix.

4.1 Environnement de travail

Cette section présente l’environnement de travail mobilisé pour le développement de la plateforme IDP, sur le plan matériel d’une part et sur le plan logiciel d’autre part.

4.1.1 Environnement matériel

Le développement de la plateforme IDP a été réalisé sur le poste de travail dont les caractéristiques sont résumées dans le Tableau 4.1.

TABLE 4.1 – Caractéristiques de l’environnement matériel de développement

Composant	Caractéristique
Processeur (CPU)	Intel Core i5-1145G7 @ 2.60 GHz (4 cœurs / 8 threads, 11ème génération)
Mémoire vive (RAM)	8 Go
Stockage	238 Go SSD
Système d’exploitation	Windows 11 Enterprise 64-bit
Carte graphique (GPU)	Intel Iris Xe Graphics (1 Go VRAM partagée)

4.1.2 Environnement logiciel

Les paragraphes suivants présentent successivement les langages de programmation, les logiciels et éditeurs, les bibliothèques Python, l'architecture des interfaces et de l'API, ainsi que les outils de communication et de reporting mobilisés pour le développement de la plateforme IDP.

Langages de programmation

Trois langages ont été utilisés pour le développement de la plateforme IDP :

- Python 3.11 : langage principal du pipeline de Machine Learning (acquisition, préparation, feature engineering, entraînement des modèles, moteur de scoring) ainsi que du backend de l'API REST (FastAPI).
- TypeScript : langage du tableau de bord web, développé avec React et Vite, apportant un typage statique aux composants d'interface et aux appels API.
- SQL : utilisé via l'ORM SQLAlchemy pour la gestion de la base d'authentification `auth.db` (SQLite) côté backend.

Logiciels et éditeurs

Le Tableau 4.2 présente les principaux logiciels et éditeurs mobilisés au cours du projet.

TABLE 4.2 – Logiciels et éditeurs utilisés

Logo	Logiciel	Usage dans le projet
	Visual Studio Code [20]	Environnement de développement principal pour le backend FastAPI, le frontend React/TypeScript et les scripts du pipeline ML, ainsi que pour l'exploration des données, l'analyse exploratoire (EDA), le feature engineering et l'entraînement des modèles via les notebooks Jupyter exécutés directement dans VS Code (<code>src/notebooks</code>).
	Draw.io [24]	Réalisation des schémas d'architecture et de pipeline du projet (par exemple le schéma du pipeline global du Chapitre 2).
	Jira [6]	Suivi des tâches et planification du projet selon la méthodologie CRISP-DM (voir planification du Chapitre 1).
	Microsoft Teams [21]	Communication avec l'équipe encadrante et reporting d'avancement au sein du centre FIT de FORVIA.
	Power BI Desktop [13]	Conception du rapport de restitution dédié au suivi des contrats, intégré dans la plateforme via <i>Power BI Embed</i> .
	Power Automate [9]	Automatisation envisagée des flux de notification et de reporting périodique à partir des données et alertes générées par la plateforme IDP.

Bibliothèques Python

Les bibliothèques Python utilisées dans le projet sont organisées en quatre domaines : traitement des données et Machine Learning, backend de l'API, et assistant IA conversationnel (RAG). Le Tableau 4.3 les synthétise.

TABLE 4.3 – Bibliothèques Python utilisées, par domaine

Domaine	Bibliothèque	Usage
Données & Machine Learning	pandas	Manipulation des DataFrames (extraits SAP, datasets de production)
	numpy	Calcul numérique (features, scores)
	scipy	Fonctions statistiques utilisées dans l'analyse exploratoire
	matplotlib	Génération des graphiques d'analyse (EDA, performances des modèles)
	seaborn	Visualisations statistiques (distributions, corrélations)
	plotly	Visualisations interactives lors de l'exploration des données
Machine Learning	scikit-learn	Modèles supervisés/non supervisés (Régression Logistique, Random Forest, Isolation Forest, K-Means) et prétraitement
Backend (API)	fastapi	Framework de l'API REST
	uvicorn	Serveur ASGI exécutant l'application FastAPI
	sqlalchemy	ORM pour la base d'authentification SQLite
	passlib[bcrypt]	Hachage des mots de passe utilisateurs
	PyJWT	Génération et vérification des tokens JWT
	httpx	Client HTTP utilisé par les services internes
Assistant IA (RAG)	chromadb	Base vectorielle pour la recherche contextuelle (collection <code>p2p_copilot_v2</code>)
	sentence-transformers	Génération des embeddings sémantiques (<code>all-MiniLM-L6-v2</code>)
	groq	Client de l'API Groq pour la génération de réponses par le LLM <code>llama-3.3-70b-versatile</code>

Interfaces et API

La plateforme IDP repose sur trois composantes interfacées : un backend REST FastAPI, un tableau de bord React/TypeScript et une restitution Power BI.

Architecture du backend FastAPI. L'application (`api/main.py`, intitulée “*SAP P2P*”

Risk Monitoring API, version 2.0.0) est structurée en couches :

- Couche *routers* : handlers HTTP groupés par domaine fonctionnel (transactions, suppliers, risk, analytics, search, executive, alerts, supplier360, transaction360, analytics_v2, chatbot), responsables de la validation des entrées et du formatage des réponses.
- Couche *services* : logique métier encapsulée — `DataLoaderService` (chargement des données), `risk_service` (scoring), `enterprise_service` et `rag_engine` (assistant IA).
- Couche *auth* : authentification par token JWT (`jwt_handler.py`, `password.py`, `dependencies.py`).
- Couche *db* : connexion à la base SQLite (`auth.db`) via SQLAlchemy.

L'authentification de l'API repose sur un mécanisme de token JWT (*JSON Web Token*) [15], dont le déroulement — de la saisie des identifiants jusqu'à l'accès aux endpoints protégés — est détaillé par le diagramme de séquence de la Figure 4.5 (Section 4.2).

Le service `DataLoaderService` (`api/services/data_loader.py`) charge les datasets de production (répertoire `src/data/products`) en mémoire sous forme de DataFrames Pandas au démarrage de l'application, et construit des index de recherche par identifiant (`transaction_id`, `supplier_id`) pour des accès rapides. Un thread de fond (`_rag_build_thread`) construit en parallèle l'index ChromaDB de l'assistant IA. Le frontend (*p2p-enterprise-frontend*, React 18/TypeScript/Vite) consomme ces données via une couche `apiClient/backendApi`, et la restitution Power BI est intégrée en complément via un *iframe* (`reportEmbed`). Une configuration CORS (*Cross-Origin Resource Sharing*) autorise par ailleurs le frontend, servi sur un port différent, à effectuer des requêtes cross-origin en développement ; en production, les origines autorisées seraient restreintes aux domaines de confiance.

Communication et reporting

Deux outils assurent la communication et le reporting autour de la plateforme IDP :

- Power BI Desktop : conception du rapport de restitution (KPIs, transactions, contrats, alertes), publié puis intégré dans la plateforme via *Power BI Embed* (Figure 4.1). Le rapport repose sur deux sources distinctes : le jeu de données initial des documents SAP (`Documents1.csv`, dont sont dérivés `transactions_risk_table.csv` et `supplier_risk_table.csv`) pour les indicateurs de risque et de performance fournisseur, et un jeu de données dédié (`Contracts2.csv`) pour le suivi des contrats.
- Power Automate : mobilisé en appui du reporting Power BI pour l'automatisation de flux d'alerte par courrier électronique vers les équipes concernées en cas de

transactions ou fournisseurs à risque élevé (Figure 4.2), dans la continuité de l'écosystème Microsoft déjà déployé chez FORVIA. La Figure 4.3 illustre un exemple d'alerte ainsi envoyée par courrier électronique.



FIGURE 4.1 – Exemple de tableau de bord Power BI Desktop conçu pour la plateforme IDP




FIGURE 4.2 – Flux Power Automate d'automatisation des alertes

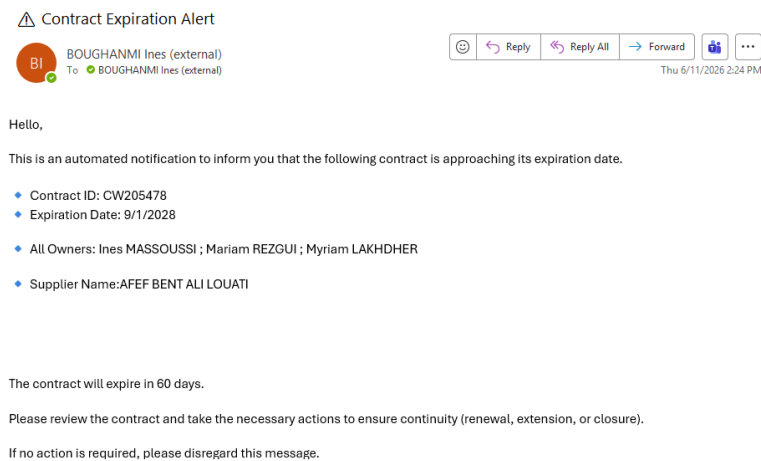


FIGURE 4.3 – Exemple d'alerte envoyée par courrier électronique aux équipes concernées

4.2 Conception de l'application

Cette section présente la conception fonctionnelle de la plateforme IDP à travers un diagramme de cas d'utilisation et deux diagrammes de séquence illustrant les principaux flux applicatifs.

4.2.1 Diagramme de cas d'utilisation

La Figure 4.4 présente les principaux cas d'utilisation de la plateforme IDP. utilisateur métier accède au dashboard, aux fonctions de recherche, aux vues 360°, au centre d'alertes, à l'assistant IA conversationnel et au rapport Power BI. Chacun de ces cas d'utilisation inclut le cas « S'authentifier » : aucun d'entre eux n'est accessible sans authentification préalable de l'utilisateur.




FIGURE 4.4 – Diagramme de cas d'utilisation de la plateforme IDP

4.2.2 Diagrammes de séquence

Authentification et accès aux endpoints protégés

La Figure 4.5 détaille le flux d'authentification par token JWT : l'utilisateur soumet ses identifiants depuis le frontend React, le backend les valide via `password.py` (hachage `bcrypt`) puis émet un token signé (PyJWT). Ce token est ensuite transmis dans l'en-tête *Authorization* de chaque requête vers les endpoints `/api/*`, où `dependencies.py` vérifie sa signature avant d'autoriser l'accès aux données servies par le `DataLoaderService`.




FIGURE 4.5 – Diagramme de séquence – Authentification JWT et accès aux endpoints protégés

Requête à l'assistant IA conversationnel

La Figure 4.6 illustre le flux de traitement d'une question posée à l'assistant IA (IDP Chatbot) : la requête transite par l'API jusqu'au **rag_engine**, qui interroge ChromaDB pour récupérer les documents les plus pertinents (recherche vectorielle), construit un prompt augmenté de ce contexte, puis l'envoie à l'API Groq pour générer la réponse finalement renvoyée à l'utilisateur.




FIGURE 4.6 – Diagramme de séquence – Requête à l’assistant IA conversationnel (RAG)

4.3 Présentation de la plateforme

La Figure 4.7 rappelle l’architecture générale de la plateforme IDP, dont les différentes interfaces sont détaillées ci-après.




FIGURE 4.7 – Architecture générale de la plateforme IDP

4.3.1 Interfaces de la plateforme

Authentification

La page de connexion (`LoginPage.tsx`) contrôle l'accès à la plateforme via un formulaire *Username/Password* : les identifiants valides donnent un token JWT (`/auth/token`) et redirigent vers le dashboard, sinon un message d'erreur générique est affiché. Cette étape garantit que seules les personnes autorisées (analystes, équipes achats/finance) accèdent aux données de risque.

Dashboard principal

Dès la connexion, la page *Dashboard* (`DashboardPage.tsx`, Figure 4.8) offre une vue exécutive synthétique de l'état des risques sur l'ensemble du périmètre P2P : cartes de statistiques (nombre de transactions/fournisseurs, scores de risque moyens, nombre de cas critiques), distribution des risques par niveau (LOW/MEDIUM/HIGH/CRITICAL), classement des fournisseurs les plus à risque (top 10), répartition par cluster, résumé des anomalies, et un encart *Executive spotlight* mettant en avant le fournisseur le plus à risque. Le dashboard permet ainsi, en un coup d'œil, d'identifier les zones de vigilance avant d'approfondir l'analyse dans les pages dédiées.



FIGURE 4.8 – Dashboard principal de la plateforme IDP

Centre d'alertes

Le centre d'alertes (Figure 4.9), alimenté par l'endpoint `/api/alerts`, regroupe les transactions et fournisseurs au niveau de risque CRITICAL ou HIGH nécessitant une attention immédiate. Il offre une vue consolidée, complémentaire au dashboard,

permettant aux équipes de prioriser leurs actions sans avoir à parcourir l'ensemble des transactions ou fournisseurs.

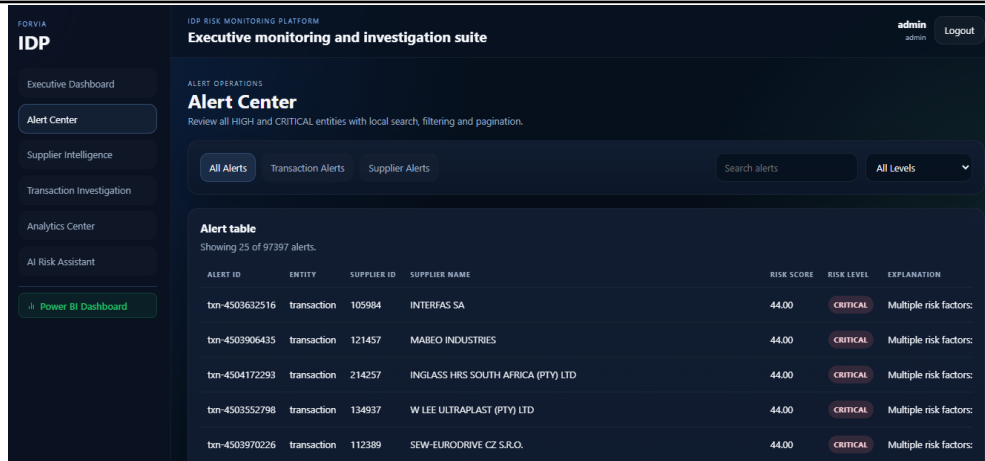


FIGURE 4.9 – Centre d’alertes de la plateforme IDP

Transactions

La page *Transactions* (`TransactionsPage.tsx`, Figure 4.10) et sa vue de détail *Transaction 360* (`TransactionDetailPage.tsx`) constituent le centre d’investigation transactionnelle : tableau paginé (identifiants, score et niveau de risque, vieillissement, écart de montant), recherche/filtrage par fournisseur, niveau de risque, score et période, et, au clic, décomposition du score, profil fournisseur associé, explication textuelle et alertes corrélées. Cette interface permet aux analystes d’investiguer individuellement les transactions anormales du processus SAP P2P en s’appuyant à la fois sur le score chiffré et sur son explication.

Transaction search results
277,924 transactions matched.

TRANSACTION ID	SUPPLIER ID	SUPPLIER NAME	RISK SCORE	RISK LEVEL	DAYS IN SYSTEM	GAP %	CREATE
4503632516	105984	INTERFAS SA	44.00	CRITICAL	763	100.00%	Jun 05
4503906435	121457	MABEO INDUSTRIES	44.00	CRITICAL	600	100.00%	Jun 05
4504172293	214257	INGLASS HRS SOUTH AFRICA (PTY) LTD	44.00	CRITICAL	444	100.00%	Jun 05
4503552798	134937	W LEE ULTRAPLAST (PTY) LTD	44.00	CRITICAL	816	100.00%	Jun 05
4503970226	112389	SEW-EURODRIVE CZ S.R.O.	44.00	CRITICAL	557	100.00%	Jun 05
4503915567	162481	EFINTOOL TECHNOLOGIE (USE_258560)	44.00	CRITICAL	412	100.00%	Jun 05

FIGURE 4.10 – Page Transactions de la plateforme IDP

Fournisseurs

La page *Suppliers* (`SuppliersPage.tsx`, Figure 4.11) et sa vue de détail *Supplier 360* (`SupplierDetailPage.tsx`) constituent le centre d'intelligence fournisseur : tableau paginé (score et niveau de risque, cluster, taux d'anomalie, fréquence de transaction, stabilité), encart *Top risk suppliers*, et, au clic, profil détaillé, métriques comportementales et d'anomalie, cluster d'appartenance (TRUSTED, STANDARD, MONITORED ou HIGH_RISK), explication textuelle du risque et transactions récentes. Le score affiché repose sur le moteur de scoring déterministe décrit au Chapitre 3 ; une explicabilité locale par SHAP est identifiée comme amélioration future (voir Conclusion générale).

Supplier search results
2,293 suppliers matched.

SUPPLIER ID	SUPPLIER NAME	RISK SCORE	RISK LEVEL
113907	CANNON FRANCE	65.68	CRITI
158773	JENDAMARK AUTOMATION (PTY) LTD	65.56	CRITI
228489	COMART	64.71	CRITI
131649	BPFAFF INDUSTRIESYSTEME(USE_260684) GMBH	64.25	CRITI
130727	CLE DE 13 PRODUCTIQUE	64.24	CRITI
198649	KINKELDER FRANCE SAS KINKELDER	62.12	CRITI
241846	KIVNON FRANCE	61.97	CRITI

Top risk suppliers
Quick executive spotlight.

SUPPLIER NAME	RISK SCORE
CANNON FRANCE (ID: 113907)	65.68
JENDAMARK AUTOMATION (PTY) LTD (ID: 158773)	65.56
COMART (ID: 228489)	64.71
BPFAFF INDUSTRIESYSTEME(USE_260684) GMBH (ID: 131649)	64.25
CLE DE 13 PRODUCTIQUE (ID: 130727)	64.24

FIGURE 4.11 – Page Fournisseurs de la plateforme IDP

Assistant IA conversationnel – IDP Chatbot

La page *Chatbot* (`ChatbotPage.tsx`, Figure 4.12) expose l'assistant IA conversationnel IDP Chatbot, implémenté selon l'architecture RAG (*Retrieval-Augmented Generation*) décrite au Chapitre 3. Le traitement d'une requête suit le flux suivant :

1. Requête utilisateur : l'analyste pose une question en langage naturel depuis la page *Chatbot*.
2. Encodage sémantique : la requête est encodée par le modèle `all-MiniLM-L6-v2` (*sentence-transformers*).
3. Récupération contextuelle : ChromaDB recherche les documents les plus similaires dans la collection persistante `p2p_copilot_v2` (similarité cosinus), indexant fournisseurs, transactions et contrats (`Contracts.csv`).
4. Construction du prompt : les métadonnées récupérées sont assemblées en un contexte structuré.
5. Génération de la réponse : le contexte est transmis à l'API Groq (modèle `llama-3.3-70b-versatile`, `temperature=0.0`, `max_tokens=900`) qui génère la réponse.
6. Fallback déterministe : en l'absence de clé `GROQ_API_KEY` ou en cas d'erreur réseau, une réponse structurée est construite directement depuis les métadonnées récupérées, garantissant la disponibilité du service.

Choix du moteur de génération : d'Ollama vers l'API Groq. Lors des premières itérations, le moteur de génération retenu était Ollama, exécuté localement (`http://127.0.0.1:11434`) avec le modèle léger `llama3.2:1b`. Cette solution fonctionnait hors-ligne mais présentait des limites en conditions réelles, ce qui a conduit à la remplacer par l'API Groq (modèle `llama-3.3-70b-versatile`). Le Tableau 4.4 synthétise cette comparaison.

TABLE 4.4 – Comparaison entre Ollama (local) et l'API Groq

Critère	Ollama (local, llama3.2:1b)	API Groq (llama-3.3-70b-versatile)
Hébergement	Local, nécessite un serveur Ollama actif sur la machine hôte	Cloud, accessible via une simple requête REST avec une clé <code>GROQ_API_KEY</code>
Taille du modèle	1 milliard de paramètres (modèle compact)	70 milliards de paramètres
Qualité de génération	Réponses parfois imprécises ou peu structurées sur des contextes longs et des consignes strictes	Réponses précises, bien structurées et respectant fidèlement les consignes du prompt système (format des scores, identifiants, niveaux de risque)
Ressources matérielles	Consomme du CPU/GPU local pendant l'inférence, ce qui peut ralentir l'API FastAPI hébergée sur la même machine	Aucune ressource locale consommée : l'inférence est déportée sur l'infrastructure Groq (LPU)
Latence	Variable selon la machine hôte, plus élevée sans GPU dédié	Très faible latence grâce à l'architecture LPU (<i>Language Processing Unit</i>) optimisée pour l'inférence
Déploiement	Peu adapté à un déploiement cloud/conteneurisé léger (nécessite d'embarquer le serveur Ollama et le modèle)	Service managé, accessible depuis n'importe quel environnement de déploiement sans dépendance lourde
Coût	Gratuit (matériel local)	Gratuit dans les limites du <i>free tier</i> Groq, sans investissement matériel supplémentaire

La page *Chatbot* (Figure 4.12) propose une interface de conversation classique (bulles utilisateur/assistant, défilement automatique, indicateur de chargement), permettant à un analyste de formuler des questions en langage naturel sur les risques fournisseurs, transactionnels ou contractuels sans naviguer manuellement dans les autres pages.

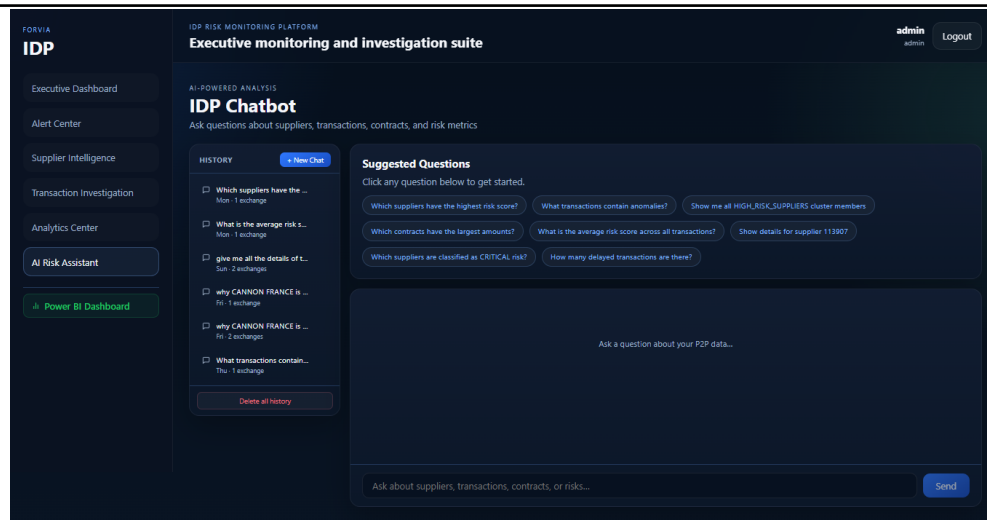


FIGURE 4.12 – Assistant IA conversationnel IDP Chatbot

Analytics

La page *Analytics* (`AnalyticsPage.tsx`) offre une vue dédiée à l’analyse globale des distributions de risque, complémentaire au dashboard principal : distribution des risques, classement des fournisseurs (top 10), répartition par cluster et bloc anomalies (taux et nombre de transactions anormales ou en retard). Actualisée via les mêmes endpoints que le dashboard, cette page centralise les indicateurs utilisés pour le reporting périodique (revues de risque, comités achats), indépendamment de l’exploration transaction par transaction.

Suivi des contrats (Power BI)

La page *Power BI* (`PowerBIPage.tsx`, Figure 4.13), intitulée “Contract Monitoring Dashboard”, intègre un rapport Power BI embarqué (*Power BI Embed*) portant sur le suivi des contrats, la performance fournisseur et les KPIs achats. Les indicateurs de risque et de performance fournisseur sont alimentés par le jeu de données initial des documents SAP (`Documents1.csv`, via `transactions_risk_table.csv` et `supplier_risk_table.csv`), tandis que le suivi contractuel s’appuie sur un jeu de données dédié (`Contracts2.csv`). Le rapport regroupe des indicateurs clés (volumes, répartition par risque, montants engagés, évolution temporelle), des tables détaillées (commandes, accords-cadres, conditions de paiement) et une vue alertes (mismatches GR/IR, factures en retard, fournisseurs à risque élevé).



FIGURE 4.13 – Restitution Power BI – suivi des contrats

Un indicateur d'état (*Loading*, *Report loaded*, *Load error*) et un bouton *Open in Power BI* (ouverture directe en cas d'indisponibilité de l'*iframe*) complètent l'intégration. Cette interface s'adresse en priorité aux utilisateurs métier déjà familiarisés avec Power BI, en continuité avec les outils de reporting de FORVIA ; couplée à Power Automate (Section 4.1.2), elle permet la diffusion automatisée d'alertes vers les équipes concernées.

4.3.2 Déploiement prévu de l'application sur Microsoft Azure

La plateforme IDP, dans son état actuel, est un prototype de haute fidélité : l'API FastAPI est exécutée localement (*uvicorn*) et le frontend React est servi par le serveur de développement Vite. Dans la perspective de son industrialisation, Microsoft Azure est envisagé comme environnement de production cible. Les sous-sections suivantes présentent les axes ayant guidé cette orientation ; il est important de souligner qu'aucun déploiement Azure n'a été réalisé à ce stade — il s'agit d'une orientation prévue pour une phase ultérieure du projet.

Simplicité de mise en œuvre

La première étape vers ce déploiement consisterait à conteneuriser les composants de la plateforme avec Docker :

- Image backend : image Python embarquant FastAPI, Uvicorn, Pandas, Scikit-learn, ChromaDB et sentence-transformers, démarrant le `DataLoaderService` puis Uvicorn.
- Image frontend : image Node.js pour la construction du frontend React (Vite), servie ensuite par une image légère (Nginx).

Ces images Docker pourraient ensuite être publiées sur un Azure Container Registry et déployées sur Azure App Service for Containers, ce qui simplifierait la mise en production : Azure App Service prendrait en charge le déploiement, le redémarrage et la mise à jour des conteneurs, sans nécessiter la gestion d'une infrastructure serveur dédiée. Un pipeline CI/CD (par exemple GitHub Actions) permettrait d'automatiser la construction des images et leur publication vers Azure Container Registry à chaque évolution du code.

Fiabilité et disponibilité

Azure App Service offrirait un niveau de disponibilité contractuel (SLA) pour l'hébergement de l'API et du frontend. L'API expose déjà un endpoint `/healthz`, qui vérifie la disponibilité du `DataLoaderService` : ce point de contrôle pourrait être utilisé par Azure App Service pour la surveillance automatique de l'état du service et le redémarrage en cas de défaillance. La répartition sur plusieurs zones de disponibilité Azure permettrait en outre de réduire le risque d'interruption de service.

Sécurité renforcée

Le déploiement sur Azure permettrait de renforcer la sécurité de la plateforme actuelle :

- Azure Key Vault pourrait être utilisé pour stocker de manière sécurisée les secrets actuellement gérés via variables d'environnement (clé `GROQ_API_KEY`, clé de signature des tokens JWT).
- Azure App Service fournirait nativement le chiffrement HTTPS des échanges entre le frontend et l'API.
- La configuration CORS, actuellement ouverte (`allow_origins=["*"]`) pour faciliter le développement local, serait restreinte aux domaines de confiance de la plateforme déployée.
- L'authentification JWT existante pourrait, à terme, être complétée par une intégration avec Microsoft Entra ID (Azure AD), cohérente avec l'écosystème Microsoft déjà utilisé par FORVIA (Power BI, Power Automate, Teams).

Adaptabilité des ressources

L'architecture actuelle repose sur des données chargées en mémoire (CSV) et une base SQLite pour l'authentification, adaptée au contexte de prototypage. Un déploiement Azure offrirait des chemins de migration adaptés à la montée en charge :

- Migration de SQLite vers Azure Database for PostgreSQL, pour la persistance des scores et des métadonnées utilisateurs.

- Utilisation d’Azure Cache for Redis pour mettre en cache les agrégations fréquemment consultées (distributions de risque, classements de fournisseurs), actuellement recalculées par le `DataLoaderService`.
- Autoscaling d’Azure App Service (ou migration vers Azure Kubernetes Service pour des besoins plus importants), permettant d’adapter dynamiquement le nombre d’instances de l’API à la charge.
- Pour une détection en quasi-temps réel, un pipeline de streaming basé sur Azure Event Hubs pourrait permettre de scorer les transactions SAP au fil de leur enregistrement.

Contrôle des coûts

Le modèle de facturation à la consommation (*pay-as-you-go*) d’Azure constituerait un avantage par rapport à une infrastructure serveur dédiée à coût fixe, en particulier pour une plateforme dont la charge varie selon les périodes (analyses ponctuelles, revues périodiques). Azure Cost Management + Budgets permettrait de suivre et de plafonner les dépenses liées à l’hébergement de l’API, du frontend et, le cas échéant, de la base de données. Des options de mise à l’échelle vers zéro (*scale-to-zero*), disponibles sur certains services Azure (par exemple Azure Container Apps), permettraient de limiter les coûts en dehors des périodes d’utilisation.

Justification du choix d’Azure

Le Tableau 4.5 compare, sur quelques critères pertinents pour la plateforme IDP, l’option Azure envisagée par rapport à d’autres solutions d’hébergement possibles.

TABLE 4.5 – Comparaison des solutions d’hébergement envisageables pour la plateforme IDP

Critère	Poste local (état actuel)	Serveur on- premise FORVIA	Microsoft Azure	Fournisseurs cloud alternatifs (AWS, GCP)
Coût initial	Nul (poste de développement)	Élevé (matériel dédié)	Faible, à la consommation	Faible, à la consommation
Effort de mise en œuvre	Aucun (déjà en place)	Élevé (provisioning, maintenance)	Modéré (App Service + conteneurs)	Modéré, mais sans intégration native avec les outils existants
Intégration écosystème Microsoft (Power BI, Power Automate, Teams)	Non applicable	Possible mais à intégrer manuellement	Native (même écosystème)	À configurer, intégration moins directe
Disponibilité / supervision	Limitée au poste de travail	Dépend de l’infrastructure interne	SLA Azure, supervision intégrée	SLA équivalent, supervision via outils tiers
Adaptabilité (montée en charge)	Aucune	Limitée, dimensionnement statique	Élevée (autoscaling, services managés)	Élevée

Conclusion

Ce chapitre a présenté l’environnement de travail et la conception de la plateforme IDP, ses différentes interfaces : authentification, dashboard, centre d’alertes, transactions et fournisseurs, assistant IA conversationnel, Analytics et restitution Power BI —, ainsi que son déploiement prévu sur Microsoft Azure. La plateforme, dans son état actuel de prototype haute fidélité, valide la faisabilité technique et la pertinence métier de l’approche développée tout au long de ce projet ; la conclusion générale qui suit revient sur l’ensemble des apports, des limites et des perspectives d’évolution, parmi lesquelles figure ce déploiement vers un environnement de production.

Conclusion générale

Ce projet de fin d'études, mené au sein du centre FIT (Faurecia Informatique Tunisie) de FORVIA, a abouti au développement complet de la plateforme IDP (Intelligent Data Platform), un système de surveillance intelligente des risques dans le processus SAP Procure-to-Pay. En suivant la méthodologie CRISP-DM, nous sommes partis de la compréhension du contexte métier de FORVIA pour aboutir à une plateforme web opérationnelle, capable d'analyser automatiquement les transactions d'achat afin d'en évaluer le niveau de risque. Cette plateforme combine plusieurs modèles de Machine Learning, un moteur de scoring qui attribue une note de risque explicable à chaque transaction, une interface web destinée aux analystes, ainsi qu'un assistant conversationnel permettant d'interroger les données en langage naturel.

Sur le plan opérationnel, la plateforme IDP apporte une réduction significative de la charge de revue manuelle en priorisant automatiquement les transactions à risque élevé ou critique. Les équipes achats et finance peuvent ainsi concentrer leur attention sur les cas les plus susceptibles d'impacter la trésorerie ou la conformité de FORVIA. Sur le plan académique, ce projet illustre l'application rigoureuse d'une démarche complète de data science à un problème industriel réel, de la compréhension du besoin jusqu'au déploiement d'une solution opérationnelle.

Le projet comporte néanmoins certaines limites. Les modèles sont entraînés en l'absence de cas de fraude réellement confirmés, ce qui peut limiter leur capacité à détecter des situations inhabituelles non couvertes par les règles métier actuelles. Le traitement des données reste par ailleurs périodique plutôt qu'en temps réel, et les performances des modèles nécessiteront un suivi régulier pour rester pertinentes dans la durée.

Les perspectives d'évolution du projet IDP portent principalement sur deux axes. Le premier concerne l'industrialisation de la plateforme, afin de la rendre plus robuste, plus facilement déployable et davantage automatisée. Le second concerne l'enrichissement des données utilisées, par l'intégration de sources externes complémentaires, afin d'affiner encore le profil de risque des fournisseurs.

Bibliographie

- [1] ANGADI, SA. *GenAI Project : RAG-Based Document Q&A with Groq API*. 2024. URL : <https://medium.com/@angadi.saa/genai-project-rag-based-document-q-a-with-groq-api-a69514d313b6>.
- [2] Leo BREIMAN. « Random Forests ». In : *Machine Learning* 45.1 (2001), p. 5-32. DOI : 10.1023/A:1010933404324.
- [3] Varun CHANDOLA, Arindam BANERJEE et Vipin KUMAR. « Anomaly Detection : A Survey ». In : *ACM Computing Surveys* 41.3 (2009), p. 1-58. DOI : 10.1145/1541880.1541882.
- [4] Nitesh V. CHAWLA et al. « SMOTE : Synthetic Minority Over-sampling Technique ». In : *Journal of Artificial Intelligence Research* 16 (2002), p. 321-357. DOI : 10.1613/jair.953.
- [5] Tianqi CHEN et Carlos GUESTRIN. « XGBoost : A Scalable Tree Boosting System ». In : *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)*. 2016, p. 785-794. DOI : 10.1145/2939672.2939785.
- [6] CLEANPNG. *Jira Logo*. 2024. URL : <https://www.cleanpng.com/free/jira.html>.
- [7] CONSULEDGE. *Mastering Random Forests : A Beginner's Guide to Smarter Machine Learning*. 2024. URL : <https://consuledge.com.au/blog/mastering-random-forests-a-beginners-guide-to-smarter-machine-learning/>.
- [8] David R. COX. « The Regression Analysis of Binary Sequences ». In : *Journal of the Royal Statistical Society, Series B* 20.2 (1958), p. 215-242.
- [9] DASHBOARD ICONS. *Microsoft Power Automate Icon*. 2024. URL : <https://dashboardicons.com/icons/microsoft-power-automate>.
- [10] DATA SCIENCE PM. *SEMMA : Sample, Explore, Modify, Model, Assess*. 2024. URL : <https://www.datascience-pm.com/semma/>.
- [11] DATA SCIENCE PM. *TDSP : Team Data Science Process*. 2024. URL : <https://www.datascience-pm.com/tdsp/>.
- [12] FORVIA. *FORVIA — Site officiel du groupe*. 2024. URL : <https://www.forvia.com/>.

- [13] ICONS8. *Power BI Icon*. 2024. URL : <https://icons8.com/icons/set/power-bi>.
- [14] INCLUDEHELP. *KDD Process in Data Mining*. 2024. URL : <https://www.includehelp.com/basics/kdd-process-in-data-mining.aspx>.
- [15] Michael B. JONES, John BRADLEY et Nat SAKIMURA. *JSON Web Token (JWT)*. Rapp. tech. RFC 7519. Internet Engineering Task Force (IETF), 2015. DOI : 10.17487/RFC7519.
- [16] Guolin KE et al. « LightGBM : A Highly Efficient Gradient Boosting Decision Tree ». In : *Advances in Neural Information Processing Systems (NIPS)*. T. 30. 2017.
- [17] Patrick LEWIS et al. « Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks ». In : *Advances in Neural Information Processing Systems (NeurIPS)*. T. 33. 2020, p. 9459-9474.
- [18] Fei Tony LIU, Kai Ming TING et Zhi-Hua ZHOU. « Isolation Forest ». In : *Proceedings of the 8th IEEE International Conference on Data Mining (ICDM)*. 2008, p. 413-422. DOI : 10.1109/ICDM.2008.17.
- [19] James B. MACQUEEN. « Some Methods for Classification and Analysis of Multivariate Observations ». In : *Proceedings of the 5th Berkeley Symposium on Mathematical Statistics and Probability*. T. 1. 1967, p. 281-297.
- [20] MICROSOFT. *Visual Studio Code — Code Editing, Redefined*. 2024. URL : <https://code.visualstudio.com/>.
- [21] MOZILLA FOUNDATION. **Privacy Not Included — Microsoft Teams*. 2024. URL : <https://www.mozillafoundation.org/fr/privacynotincluded/teams/>.
- [22] NVIDIA. *What is XGBoost?* 2024. URL : <https://www.nvidia.com/en-in/glossary/xgboost/>.
- [23] OPEN DATA SCIENCE. *How the Logistic Regression Model Works in Machine Learning*. 2024. URL : <https://opendatascience.com/how-the-logistic-regression-model-works-in-machine-learning/>.
- [24] SCICODING. *Use draw.io*. 2023. URL : <https://scicoding.com/use-di/>.
- [25] WAINAINA, PIERRE. *Mastering Data Science with CRISP-DM Methodology : A Step-by-Step Guide*. 2024. URL : <https://medium.com/@wainaina.pierre/mastering-data-science-with-crisp-dm-methodology-a-step-by-step-guide-a976b71257b5>.